

Voetbal door de Lens van Data: Analyse en Visualisatie



Naam: Sven Bruning

Studentnummer: 5667259

Opleiding: Technische Informatica

Introduction	3
Background & Objectives	4
Background	4
Objectives	4
Technical Design & Implementation	5
Dataset & Database	5
Data-acquisitie & Preprocessing	8
Exploratory Data Analysis (EDA)	13
Visualisations	22
Results & Evaluation	38
Results	38
Evaluation	40
Discussion & Future Work	41
Discussion	41
Future Work	43
Conclusion	44

Introduction

Voetbal is wereldwijd de populairste sport en genereert dagelijks grote hoeveelheden data. Statistieken zoals doelpunten, schoten op doel, balbezit, passes en kaarten worden verzameld en vastgelegd voor wedstrijden over de hele wereld. Deze gegevens bieden niet alleen inzicht in individuele teamprestaties, maar kunnen ook gebruikt worden om trends, patronen en strategische inzichten te ontdekken.

Hoewel veel data beschikbaar is, is het vaak een uitdaging om deze informatie op een overzichtelijke en zinvolle manier te analyseren. Onbewerkte datasets zijn moeilijk te interpreteren en vereisen gestructureerde methoden voor exploratie en visualisatie. Data-analyse biedt de mogelijkheid om voetbalstatistieken op een systematische manier te onderzoeken, verbanden te identificeren en overzichtelijke inzichten te creëren.

Dit project richt zich op het analyseren van voetbalstatistieken met R en RStudio, met als doel het ontdekken van trends, patronen en inzichten in wedstrijddatasets. Het project concentreert zich op drie kernactiviteiten van datascience:

1. **Data-acquisitie en preprocessing:** het verzamelen, opschonen en voorbereiden van de dataset voor analyse.
2. **Exploratory Data Analysis (EDA):** het verkennen van data om interessante statistische patronen te identificeren.
3. **Data Visualisatie:** het presenteren van analyses in grafieken en tabellen om de bevindingen inzichtelijk te maken.

Het project streeft ernaar een diepgaand inzicht te bieden in voetbaldata en laat zien hoe gestructureerde analyse en visualisatie kunnen bijdragen aan een beter begrip van wedstrijdprestaties.

De rest van dit verslag is als volgt opgebouwd: in Background & Objectives wordt de context en het doel van het project beschreven. In Technical Design & Implementation wordt de dataset, de analysemethoden en de implementatie in R besproken. In Results & Evaluation worden de belangrijkste bevindingen en grafische visualisaties gepresenteerd, en in Discussion & Future Work volgt een reflectie op de resultaten en suggesties voor toekomstige uitbreiding van het project.

Background & Objectives

Background

Voetbal genereert een grote hoeveelheid data per seizoen, zoals informatie over wedstrijden, teams, spelers en prestaties. Voor clubs, analisten en onderzoekers kan deze data waardevolle inzichten bieden in trends, strategieën en succesfactoren.

Voor dit project wordt gebruikgemaakt van de European Soccer Database (beschikbaar op Kaggle). Deze dataset bevat:

- **Wedstrijdgegevens:** datum, competitie, seizoen, doelpunten, schoten, balbezit, kaarten, uitslag.
- **Teamstatistieken:** teams, ranglijst, punten, doelpunten voor en tegen.
- **Spelersstatistieken:** goals, assists, speelminuten, positie, kaarten.

Deze dataset is geschikt om patronen en trends in wedstrijden, teams en spelers over meerdere seizoenen te onderzoeken.

Objectives

Het project heeft de volgende concrete doelstellingen:

1. Data-acquisitie en voorbereiding:
 - Downloaden van de dataset van Kaggle en importeren in RStudio.
 - Opschonen van de data: verwijderen van ontbrekende waarden in kritieke kolommen (zoals doelpunten of uitslagen), converteren van datatypes (bijv. datum naar Date, numerieke waarden), samenvoegen van gerelateerde tabellen (bijv. wedstrijd- en teamstatistieken)
2. Exploratory Data Analysis (EDA):
 - Onderzoeken van verdelingen van doelpunten, balbezit, schoten en kaarten.
 - Analyse van trends over seizoenen en competities.
 - Vergelijkingen tussen teams, zoals thuis- vs. uitprestaties.
 - Correlatieanalyse tussen statistieken, bijvoorbeeld schoten vs. doelpunten, balbezit vs. winstkans
3. Data Visualisatie:
 - Creëren van grafieken in R (ggplot2) om inzichten duidelijk te maken, bijvoorbeeld:
 - Lijnplots van gemiddelde doelpunten per seizoen per competitie.
 - Boxplots van schoten per team.
 - Heatmaps van correlaties tussen statistieken.
 - Tabellen met samenvattende statistieken per team of speler.
4. Interpretatie en conclusies:
 - Identificeren van belangrijke trends en factoren die succes beïnvloeden
 - Kritisch reflecteren op beperkingen van de dataset.
 - Voorstellen van mogelijke vervolgonderzoeken of uitbreidingen van de analyses

Technical Design & Implementation

Dataset & Database

Voor dit project wordt gebruikgemaakt van de European Soccer Database, een dataset die beschikbaar is gesteld op Kaggle. Deze dataset is opgebouwd als een SQLite database (database.sqlite) en bevat gegevens van meer dan 25.000 voetbalwedstrijden, 11.000 spelers, 300 teams en 2008-2016 seizoenen uit 11 Europese landen.

Alle tabellen in de database

1. Country

Bevat informatie over landen waarin competities plaatsvinden.

Belangrijke velden:

- `id` - unieke identificatie van het land
- `name` - naam van het land (bijv. "Spain")

2. League

Bevat informatie over competities in verschillende landen.

Belangrijke velden:

- `id` - unieke identificatie van de competitie
- `country_id` - koppeling naar Country
- `name` - naam van de competitie (bijv. "Germany 1. Bundesliga")

3. Match

Bevat informatie over individuele wedstrijden.

Belangrijke velden:

- `id` - unieke identificatie van de wedstrijd
- `season` - seizoen (bijv. "2013/2014")
- `date` - datum van de wedstrijd
- `home_team_api_id`, `away_team_api_id` - koppeling naar teams
- `home_team_goal`, `away_team_goal` - aantal doelpunten

4. Team

Bevat informatie over voetbalteams.

Belangrijke velden:

- `team_api_id` - unieke sleutel voor koppeling met Match
- `team_long_name` - volledige naam van het team
- `team_short_name` - afkorting

5. Team_Attributes

Bevat statistieken en speelstijl van teams over de tijd.

Belangrijke velden:

- `team_api_id` - koppeling naar Team
- `date` - datum van de meting
- `buildUpPlaySpeed` - snelheid van de opbouw
- `defencePressure` - verdedigingsdruk

6. Player

Bevat informatie over spelers.

Belangrijke velden:

- `player_api_id` - unieke speler-ID
- `player_name` - naam van de speler
- `birthday` - geboortedatum
- `height` - lengte (cm)
- `weight` - gewicht (lbs)

7. Player_Attributes

Bevat statistieken en vaardigheden van spelers door de tijd heen.

Belangrijke velden:

- `player_api_id` - koppeling naar Player
- `date` - datum van meting
- `overall_rating` - algemene rating
- `potential` - potentieel
- `preferred_foot` - links of rechts
- `attacking_work_rate`, `defensive_work_rate` - werkethiek

Waarom SQLite?

De European Soccer Database is standaard beschikbaar in het SQLite-formaat. Dit betekent dat alle gegevens zijn opgeslagen in een enkel bestand (`database.sqlite`). SQLite is relationeel opgezet: de tabellen zijn met elkaar verbonden via primaire en vreemde sleutels, waardoor analyses op verschillende niveaus, zoals wedstrijden, teams en spelers, goed mogelijk zijn.

Daarnaast integreert SQLite uitstekend met R: via de packages DBI en RSQLite kan eenvoudig verbinding worden gemaakt en kunnen tabellen direct worden ingelezen als dataframes. Het gebruik van SQLite biedt hiermee een praktische en toegankelijke basis voor verdere analyses en visualisaties.

Voorbeeldcode: database openen en tabellen bekijken

Onderstaande R-code laat zien hoe de database kan worden geopend en hoe enkele tabellen kunnen worden bekeken:

```
library(DBI)
library(RSQLite)

# Verbinding maken met de database
connection <- dbConnect(SQLite(), "database/database.sqlite")

# Overzicht van alle tabellen in de database
dbListTables(connection)

# Eerste rijen van de Match tabel bekijken
matches_raw <- dbReadTable(connection, "Match")
head(matches_raw[, c("match_api_id", "date", "season",
```

```
"home_team_goal", "away_team_goal"]])
```

Deze code laat zien hoe de verbinding wordt gelegd, hoe je een lijst van tabellen krijgt en hoe je de belangrijkste gegevens van een tabel kunt inspecteren. Voor het volledige proces van het inlezen van alle tabellen is een apart R-script gemaakt: data_import.R.

data_import.R

```
# data_import.R
# Verbinden met SQLite database en de tabellen inlezen
library(DBI)
library(RSQLite)

# Verbinding maken met de database
connection <- dbConnect(SQLite(), "database/database.sqlite")

dbListTables(connection)

# Tabellen inlezen
countries_raw <- dbReadTable(connection, "Country")
leagues_raw <- dbReadTable(connection, "League")
matches_raw <- dbReadTable(connection, "Match")
players_raw <- dbReadTable(connection, "Player")
player_attr_raw <- dbReadTable(connection, "Player_Attributes")
teams_raw <- dbReadTable(connection, "Team")
team_attr_raw <- dbReadTable(connection, "Team_Attributes")

# Data opslaan als RData
save(countries_raw, leagues_raw, matches_raw, players_raw,
player_attr_raw, teams_raw, team_attr_raw, file =
"database/raw_data.RData")
```

Het script data_import.R is verantwoordelijk voor het verbinden met de SQLite database en het inlezen van de tabellen in R. Hiervoor worden de pakketten DBI en RSQLite gebruikt.

Eerst wordt met dbConnect(SQLite(), "database/database.sqlite") een verbinding gelegd met de database. Met dbListTables() kan worden gecontroleerd welke tabellen aanwezig zijn. Vervolgens worden de tabellen Country, League, Match, Player, Player_Attributes, Team en Team_Attributes ingelezen met dbReadTable().

Om het werken met de data in latere scripts efficiënter te maken, worden alle ingelezen tabellen samengevoegd en opgeslagen in een enkel bestand (raw_data.RData). Dit maakt het mogelijk om de ruwe data direct te laden in volgende stappen (preprocessing, EDA en visualisatie), zonder opnieuw de database te hoeven openen.

Data-acquisitie & Preprocessing

Data-acquisitie

De eerste stap in dit project bestond uit het verzamelen en inladen van de dataset. Hiervoor is de European Soccer Database gebruikt, een rijke dataset in SQLite-formaat met tabellen zoals *Country*, *League*, *Match*, *Player*, *Player_Attributes*, *Team* en *Team_Attributes*.

Voor het inladen van de tabellen is het script `data_import.R` ontwikkeld. Dit script maakt via de R-packages DBI en RSQLite verbinding met het bestand `Data/database.sqlite` en leest alle tabellen in als R-dataframes. Omdat dit proces relatief zwaar kan zijn en niet bij iedere analyse opnieuw uitgevoerd hoeft te worden, zijn de ingelezen tabellen gebundeld en opgeslagen in een enkel bestand: `raw_data.RData`.

Dit bestand vormt het uitgangspunt voor de preprocessing stap. Op die manier kan in volgende scripts snel en efficiënt met de data worden gewerkt, zonder telkens een nieuwe verbinding met de SQLite database te moeten maken.

Hoewel de dataset zeer rijk is, is ze niet direct bruikbaar voor analyse. Enkele belangrijke uitdagingen zijn:

- **Grote omvang:** de database bevat informatie van meer dan 25.000 wedstrijden, duizenden spelers en meerdere seizoenen, waardoor de data omvangrijk en complex is.
- **Missende waarden:** in tabellen zoals *Player_Attributes* ontbreken geregeld waardes voor spelersratings of werkethiek.
- **Inconsistente datatypes:** sommige velden zijn als tekst opgeslagen (bijvoorbeeld datums) terwijl ze in feite numeriek of Date moeten zijn.
- **Overbodige kolommen:** veel tabellen bevatten velden die niet relevant zijn voor dit project, zoals gedetailleerde technische velden of duplicaten van identifiers.

Preprocessing

Het preprocessingsproces is ingericht met de volgende doelen:

1. **Opschonen** - verwijderen of corrigeren van missende en inconsistente waarden.
2. **Structureren** - reduceren tot relevante variabelen, en correct instellen van datatypes.
3. **Verrijken** - creëren van nieuwe variabelen en samenvattende statistieken die de analyses krachtiger maken.
4. **Opslaan van schone data** - het genereren van een nieuw bestand (`clean_data.RData`) dat direct kan worden gebruikt voor Exploratory Data Analysis en Visualisaties

Stappenplan:

1. Selectie van kernvariabelen

Uit de ruwe tabellen zijn relevante kolommen geselecteerd voor de analyse:

- **Match:** `match_api_id`, `country_id`, `league_id`, `season`, `stage`, `date`, `home_team_api_id`, `away_team_api_id`, `home_team_goal`, `away_team_goal`.
- **Player_Attributes:** `player_api_id`, `player_fifa_api_id`, `date`, `overall_rating`, `potential`, `dribbling`, `finishing`.

- **Team_Attributes:** team_api_id, date, buildUpPlaySpeed, buildUpPlayPassing, chanceCreationPassing, chanceCreationShooting, defencePressure, defenceAggression.

2. Veilige conversie naar numerieke waarden

Veel kolommen zijn in de ruwe data als tekst of factor opgeslagen. Met een veilige conversiefunctie (safe_numeric) zijn deze kolommen geconverteerd naar numeriek, waarbij eventuele niet-numerieke waarden genegeerd worden. Geconverteerde kolommen zijn onder andere:

- **matches:** home_team_goal, away_team_goal
- **player_attr:** overall_rating, potential, dribbling, finishing
- **team_attr:** buildUpPlaySpeed, chanceCreationShooting, defencePressure

3. Opschonen van missende waarden

Numerieke kolommen met ontbrekende waarden zijn opgeschoond door de mediaan van de kolom in te vullen.

4. Conversie van datatypes

- **Datums:** kolommen zoals date in matches, player_attr en team_attr zijn omgezet naar het Date formaat.

5. Feature Engineering

Om analyses te verrijken, zijn nieuwe variabelen toegevoegd:

- **goal_difference:** verschil tussen doelpunten van thuis- en uitteam
- **match_result:** classificatie van wedstrijd als "Home Win", "Away Win" of "Draw".
- **total_goals:** totaal aantal doelpunten per wedstrijd

6. Competitienamen koppelen

In deze stap zijn de competitienamen gekoppeld aan de wedstrijden om de analyses beter te maken

7. Samenvattende statistieken

- **player_summary:** gemiddelde statistieken per speler voor overall_rating, potential, dribbling en finishing
- **team_summary:** gemiddelde tactische en verdedigende eigenschappen per team, zoals buildUpPlaySpeed, chanceCreationShooting en defencePressure.

8. Teamattributen koppelen aan wedstrijden

In deze stap zijn de teamstatistieken uit de tabel team_summary gekoppeld aan de matches dataset

preprocessing.R

```
# preprocessing.R

# Laden van benodigde packages
```

```

library(dplyr)
library(lubridate)

# Laden van ruwe data
load("Data/raw_data.RData")

# 1. Selectie van kernvariabelen
matches <- matches_raw %>%
  select(match_api_id, country_id, league_id, season, stage, date,
         home_team_api_id, away_team_api_id,
         home_team_goal, away_team_goal)

player_attr <- player_attr_raw %>%
  select(player_api_id, player_fifa_api_id, date,
         overall_rating, potential, dribbling, finishing)

team_attr <- team_attr_raw %>%
  select(team_api_id, date,
         buildUpPlaySpeed, buildUpPlayPassing,
         chanceCreationPassing, chanceCreationShooting,
         defencePressure, defenceAggression)

# 2. Veilige conversie naar numeric
safe_numeric <- function(x) {
  x_char <- as.character(x)
  suppressWarnings(as.numeric(x_char))
}

num_cols_matches <- c("home_team_goal", "away_team_goal")
matches[num_cols_matches] <- lapply(matches[num_cols_matches],
safe_numeric)

num_cols_player <- c("overall_rating", "potential", "finishing",
"dribbling")
player_attr[num_cols_player] <- lapply(player_attr[num_cols_player],
safe_numeric)

num_cols_team <- c("buildUpPlaySpeed", "buildUpPlayPassing",
"chanceCreationPassing",
"chanceCreationShooting", "defencePressure",
"defenceAggression")
team_attr[num_cols_team] <- lapply(team_attr[num_cols_team],
safe_numeric)

# 3. Opschonen van missende waarden
impute_median <- function(x) {

```

```

    if (is.numeric(x)) x[is.na(x)] <- median(x, na.rm = TRUE)
    return(x)
}

matches <- as.data.frame(lapply(matches, impute_median))
player_attr <- as.data.frame(lapply(player_attr, impute_median))
team_attr <- as.data.frame(lapply(team_attr, impute_median))

# 4. Conversie van datatypes
matches$date <- as.Date(matches$date)
player_attr$date <- as.Date(player_attr$date)
team_attr$date <- as.Date(team_attr$date)

# 5. Feature Engineering
matches <- matches %>%
  mutate(
    goal_difference = home_team_goal - away_team_goal,
    match_result = case_when(
      goal_difference > 0 ~ "Home Win",
      goal_difference < 0 ~ "Away Win",
      TRUE ~ "Draw"
    ),
    total_goals = home_team_goal + away_team_goal,
  )

# 6. Competitienamen koppelen
matches <- matches %>%
  left_join(leagues_raw %>% select(id, name), by = c("league_id" =
    "id")) %>%
  rename(league_name = name)

# 7. Samenvattende statistieken
player_summary <- player_attr %>%
  group_by(player_api_id) %>%
  summarise(
    avg_rating = mean(overall_rating, na.rm = TRUE),
    avg_potential = mean(potential, na.rm = TRUE),
    avg_finishing = mean(finishing, na.rm = TRUE),
    avg_dribbling = mean(dribbling, na.rm = TRUE)
  )

team_summary <- team_attr %>%
  group_by(team_api_id) %>%
  summarise(
    avg_buildUpSpeed = mean(buildUpPlaySpeed, na.rm = TRUE),
    avg_buildUpPassing = mean(buildUpPlayPassing, na.rm = TRUE),

```

```

    avg_chanceCreationPassing = mean(chanceCreationPassing, na.rm =
TRUE),
    avg_chanceCreationShooting = mean(chanceCreationShooting, na.rm =
TRUE),
    avg_defencePressure = mean(defencePressure, na.rm = TRUE),
    avg_defenceAggression = mean(defenceAggression, na.rm = TRUE)
)

# 8. Teamattributen koppelen aan wedstrijden.
matches <- matches %>% left_join(team_summary, by = c("home_team_api_id"
= "team_api_id"))

# 9. Opslaan van schone datasets
save(matches, player_attr, team_attr, player_summary, team_summary,
countries_raw, leagues_raw, teams_raw, players_raw,
file = "Data/clean_data.RData")

```

Na deze stappen zijn de datasets volledig opgeschoond, verrijkt en geschikt voor analyse:

- **matches:** bevat per wedstrijd de uitslag, doelpunten, match_result, goal_difference, total_goals, gekoppelde competitienamen en teamstatistieken van het thuisspelende team.
- **player_attr:** bevat opgeschoonde spelersstatistieken zonder missende waarden.
- **team_attr:** bevat opgeschoonde tactische teamstatistieken, zoals build-up play, passing en verdediging.
- **player_summary & team_summary:** bevatten gemiddelde speler- en teamstatistieken, bruikbaar voor vergelijkingen en trendanalyses.

Deze schone en verrijkte datasets vormen een solide en consistente basis voor de Exploratory Data Analysis (EDA) en de daaropvolgende visualisaties en modellen.

Exploratory Data Analysis (EDA)

De Exploratory Data Analysis (EDA) vormt een cruciale fase binnen dit project waarin de opgeschoonde dataset systematisch wordt onderzocht om inzicht te krijgen in patronen, trends en onderlinge relaties tussen variabelen. Het doel van deze analyse is om de dataset niet enkel kwantitatief te beschrijven, maar vooral om onderliggende structuren en patronen zichtbaar te maken die later met behulp van visualisaties verder kunnen worden geïnterpreteerd.

De analyses in dit hoofdstuk zijn voornamelijk uitgevoerd op de tabel matches, afkomstig uit de opgeschoonde dataset `clean_data.RData`. Deze tabel bevat informatie over wedstrijden, doelpunten, teams, seizoenen en resultaten.

Het EDA-proces is uitgevoerd met R en richt zich voornamelijk op:

1. Het beschrijven van de dataset en controleren van volledigheid.
2. Het berekenen van kernstatistieken zoals doelpuntgemiddelden en uitslagverdeling.
3. Het analyseren van trends per seizoen en competitie.
4. Het onderzoeken van relaties tussen speelstijl en prestaties.
5. Het identificeren van verbanden tussen variabelen via correlatieanalyses

Algemene datasetverkenning.

De eerste stap van de EDA richt zich op het verkrijgen van een globaal overzicht van de dataset. Het doel is om de omvang, spreiding en structuur van de gegevens in kaart te brengen en inzicht te krijgen in de representativiteit van de data.

Code:

```
# 1. Algemene samenvatting van de dataset
cat("ALGEMENE SAMENVATTING\n")
cat("Aantal wedstrijden:", nrow(matches), "\n")
cat("Aantal unieke seizoenen:", length(unique(matches$season)), "\n")
cat("Aantal competities:", length(unique(matches$league_name)), "\n")
cat("Aantal teams:", length(unique(c(matches$home_team_api_id, matches$away_team_api_id))), "\n\n")
```

Output:

```
ALGEMENE SAMENVATTING
Aantal wedstrijden: 25979
Aantal unieke seizoenen: 8
Aantal competities: 11
Aantal teams: 299
```

Analyse:

De dataset omvat 25.979 wedstrijden verspreid over 8 seizoenen en 11 competities in Europa, met bijna 300 unieke teams. Deze omvang biedt voldoende diepgang voor statistische betrouwbaarheid en maakt vergelijkingen mogelijk tussen competities, teams en seizoenen. De aanwezigheid van meerdere seizoenen vergroot bovendien de mogelijkheid om trends in tijd te analyseren.

Basisstatistieken over doelpunten.

Een belangrijk aspect in voetbalanalyses is het scoringsgedrag van teams. Door middel van een samenvattende statistische analyse worden het gemiddelde, de mediaan en de verschillen tussen thuis- en uitdoelpunten berekend

Code:

```
# 2. Basisstatistieken over doelpunten
match_stats <- matches %>%
  summarise(
    gemiddeld_totaal_doelpunten = mean(total_goals, na.rm = TRUE),
    mediaan_totaal_doelpunten = median(total_goals, na.rm = TRUE),
    gemiddeld_thuisdoelpunten = mean(home_team_goal, na.rm = TRUE),
    gemiddeld_uitdoelpunten = mean(away_team_goal, na.rm = TRUE),
    gemiddeld_doelpuntverschil = mean(goal_difference, na.rm = TRUE)
  )

cat("BASISSTATISTIEKEN VAN WEDSTRIJDEN\n")
cat(sprintf("Gemiddeld totaal doelpunten: %.2f\n", match_stats$gemiddeld_totaal_doelpunten))
cat(sprintf("Mediaan totaal doelpunten: %.2f\n", match_stats$mediaan_totaal_doelpunten))
cat(sprintf("Gemiddeld thuisdoelpunten: %.2f\n", match_stats$gemiddeld_thuisdoelpunten))
cat(sprintf("Gemiddeld uitdoelpunten: %.2f\n", match_stats$gemiddeld_uitdoelpunten))
cat(sprintf("Gemiddeld doelpuntenverschil: %.2f\n", match_stats$gemiddeld_doelpuntverschil))
```

Output:

```
BASISSTATISTIEKEN VAN WEDSTRIJDEN
Gemiddeld totaal doelpunten: 2.71
Mediaan totaal doelpunten: 3.00
Gemiddeld thuisdoelpunten: 1.54
Gemiddeld uitdoelpunten: 1.16
Gemiddeld doelpuntenverschil: 0.38
```

Analyse:

Gemiddeld vallen er 2.71 doelpunten per wedstrijd, wat een vrij aanvallend karakter van Europese competities weerspiegelt. De mediaan van 2 doelpunten suggereert dat de verdeling iets naar boven is verschoven, veel wedstrijden eindigen met 2 a 3 doelpunten. De verschillen tussen thuis- (1.54) en uitdoelpunten (1.16) bevestigen het statistisch bekende thuisvoordeel, waarbij thuisploegen gemiddeld 0.38 doelpunten meer scoren. Deze statistiek vormt de basis voor latere analyses rond winstkansen en teamvoordelen.

Verdeling van wedstrijdresultaten.

De volgende stap onderzoekt hoe vaak wedstrijden eindigen in winst, verlies of gelijkspel. Door deze verdeling te analyseren wordt duidelijk hoe competitief en evenwichtig de dataset is.

Code:

```
# 3. Verdeling van wedstrijdresultaten
result_distribution <- matches %>%
  group_by(match_result) %>%
  summarise(aantal = n()) %>%
  mutate(percentage = round(aantal / sum(aantal) * 100, 2))

cat("\nVERDELING VAN WEDSTRIJDRESULTATEN\n")
print(result_distribution)
```

Output:

```
VERDELING VAN WEDSTRIJDRESULTATEN
# A tibble: 3 × 3
  match_result aantal percentage
  <chr>         <int>         <dbl>
1 Away Win      7466          28.7
2 Draw          6596          25.4
3 Home Win     11917          45.9
```

Analyse:

Bijna 46% van de wedstrijden eindigt in winst voor het thuisteam, terwijl slechts 29% wordt gewonnen door het uitteam. Gelijkspelen (25%) komt minder vaak voor, maar vormt een substantiële categorie. Deze verdeling benadrukt dat het thuisvoordeel niet enkel in doelpunten, maar ook in eindresultaten tot uiting komt.

Gemiddelde doelpunten per seizoen en competitie.

Om de evolutie van scoringspatronen te bestuderen, is berekend hoe het gemiddelde aantal doelpunten per seizoen en competitie varieert.

Code:

```
# 4. Gemiddelde doelpunten per seizoen en competitie
trend_season_league <- matches %>%
  group_by(season, league_name) %>%
  summarise(
    gemiddeld_totaal_doelpunten = mean(total_goals, na.rm = TRUE),
    gemiddeld_thuisdoelpunten = mean(home_team_goal, na.rm = TRUE),
    gemiddeld_uitdoelpunten = mean(away_team_goal, na.rm = TRUE),
    aantal_wedstrijden = n(),
    .groups = "drop"
  ) %>%
  arrange(season)

cat("\nGEMIDDELDE DOELPUNTEN PER SEIZOEN EN COMPETITIE\n")
print(trend_season_league)
```

Output:

```
GEMIDDELDE DOELPUNTEN PER SEIZOEN EN COMPETITIE
# A tibble: 88 × 6
  season league_name      gemiddeld_totaal_doelpunten gemiddeld_thuisdoelpunten gemiddeld_uitdoelpunten aantal_wedstrijden
  <chr>   <chr>                <dbl>                <dbl>                <dbl>                <int>
1 2008/2009 Belgium Jupiler League      2.79                1.63                1.16                306
2 2008/2009 England Premier League      2.48                1.4                1.08                380
3 2008/2009 France Ligue 1              2.26                1.29                0.971               380
4 2008/2009 Germany 1. Bundesliga        2.92                1.70                1.22                306
5 2008/2009 Italy Serie A                 2.6                1.52                1.08                380
6 2008/2009 Netherlands Eredivisie      2.84                1.71                1.13                306
7 2008/2009 Poland Ekstraklasa           2.18                1.34                0.846               240
8 2008/2009 Portugal Liga ZON Sagres     2.3                1.23                1.07                240
9 2008/2009 Scotland Premier League     2.40                1.32                1.08                228
10 2008/2009 Spain LIGA BBVA              2.90                1.66                1.24                380
# 78 more rows
# Use `print(n = ...)` to see more rows
```

Analyse:

De resultaten tonen aan dat het gemiddelde aantal doelpunten per seizoen relatief stabiel blijft binnen individuele competities, met slechts kleine schommelingen van jaar tot jaar. Dit wijst op consistente scoringspatronen binnen Europese competities over de periode 2008 - 2016. Toch zijn er duidelijke structurele verschillen tussen competities.

Competities met hoge doelpuntgemiddelden:

- Nederlandse Eredivisie (vaak rond de 3.0 goals per wedstrijd).
- Zwitserse Super League (regelmatig boven de 3.0).
- Duitse Bundesliga (doorgaans rond de 2.8-3.0).

Deze competities staan bekend om aanvallende speelstijlen, minder compact verdedigen en tactieken die leiden tot open wedstrijden.

Competities met lagere gemiddelden:

- Franse Ligue 1 (ca. 2.3-2.5 goals).
- Poolse Ekstraklasa (vaak onder de 2.4).
- Italiaanse Serie A (meestal 2.5-2.7)

Hier zie je vaker een meer defensieve structuur, nadruk op organisatie, compacter spel en minder open wedstrijden.

Correlatie tussen teamstijl en prestaties

Om te onderzoeken hoe verschillende speelstijlkenmerken van teams met elkaar samenhangen, is een correlatiematrix berekend voor de belangrijkste teamattributen: opbouwsnelheid, passnauwkeurigheid bij opbouw, passing in kanscreatie, schieten bij kanscreatie, druk zetten en agressiviteit in verdediging

Code:

```
# 5. Correlatie tussen teamstijl en prestaties
team_play_corr <- matches %>%
  select(
    avg_buildUpSpeed, avg_buildUpPassing, avg_chanceCreationPassing,
    avg_chanceCreationShooting, avg_defencePressure, avg_defenceAggression
  ) %>%
  drop_na() %>%
  cor(use = "complete.obs")

cat("\nCORRELATIE TUSSEN TEAMATTRIBUTES\n")
print(round(team_play_corr, 2))
```

Output:

	avg_buildUpSpeed	avg_buildUpPassing	avg_chanceCreationPassing	avg_chanceCreationShooting	avg_defencePressure	avg_defenceAggression
avg_buildUpSpeed	1.00	0.44	0.35	0.04	-0.07	0.18
avg_buildUpPassing	0.44	1.00	0.15	-0.16	-0.21	0.11
avg_chanceCreationPassing	0.35	0.15	1.00	0.21	0.16	0.11
avg_chanceCreationShooting	0.04	-0.16	0.21	1.00	0.25	0.16
avg_defencePressure	-0.07	-0.21	0.16	0.25	1.00	0.37
avg_defenceAggression	0.18	0.11	0.11	0.16	0.37	1.00

Analyse:

- Sterke positieve correlaties zijn zichtbaar tussen avg_buildUpSpeed en avg_buildUpPassing (0.44) en tussen avg_buildUpSpeed en avg_chanceCreationPassing (0.35). Dit geeft aan dat teams die sneller opbouwen vaak ook nauwkeuriger passen en meer kansen creëren via passing.
- avg_defencePressure en avg_defenceAggression vertonen een matige positieve correlatie (0.37), wat suggereert dat teams die agressiever verdedigen ook meer druk uitoefenen op tegenstanders.
- Over het algemeen zijn de correlaties tussen aanval- en verdedigingsvariabelen vrij laag of negatief, wat erop wijst dat een aanvallende speelstijl niet per se samengaat met een sterk verdedigend profiel.

Thuis- versus uitprestaties

Om de invloed van locatie verder te kwantificeren, zijn thuis- en uitprestaties direct met elkaar vergeleken.

Code:

```
# 6. Thuis- versus uitprestaties
home_vs_away <- matches %>%
  summarise(
    gemiddeld_thuisdoelpunten = mean(home_team_goal, na.rm = TRUE),
    gemiddeld_uitdoelpunten = mean(away_team_goal, na.rm = TRUE),
    thuiswin_percentage = mean(match_result == "Home Win") * 100,
    uitwin_percentage = mean(match_result == "Away Win") * 100,
    gelijk_percentage = mean(match_result == "Draw") * 100
  )

cat("\nTHUIS- VERSUS UITPRESTATIES\n")
print(round(home_vs_away, 2))
```

Output:

	gemiddeld_thuisdoelpunten	gemiddeld_uitdoelpunten	thuiswin_percentage	uitwin_percentage	gelijk_percentage
1	1.54	1.16	45.87	28.74	25.39

Analyse:

De cijfers laten duidelijk zien dat teams gemiddeld beter presteren in thuiswedstrijden. Niet alleen scoren ze meer doelpunten (1.54 tegenover 1.16 uit), maar de thuiswinstkans ligt ook aanzienlijk hoger (45.9% tegenover 28.7%). Dit wijst op een duidelijk thuisvoordeel.

Factoren zoals steun van het publiek, vertrouwdheid met het speelveld, minder reistijd en mogelijk gunstige arbitragebeslissingen kunnen bijdragen aan dit voordeel.

Competitieanalyse

Om verschillen tussen leagues te onderzoeken, is een analyse per competitie uitgevoerd met nadruk op doelpunten en resultaatverdeling

Code:

```
# 7. Competitieanalyse
# Analyse per competitie: gemiddelde doelpunten, winstpercentages, enz
league_analysis <- matches %>%
  group_by(league_name) %>%
  summarise(
    gemiddeld_doelpunten = mean(total_goals, na.rm = TRUE),
    thuiswinst = mean(match_result == "Home Win") * 100,
    uitwinst = mean(match_result == "Away Win") * 100,
    gelijkspel = mean(match_result == "Draw") * 100,
    wedstrijden = n(),
    .groups = "drop"
  ) %>%
  arrange(desc(gemiddeld_doelpunten))

cat("\nCOMPETITIEANALYSE (TOP 10 OP GEMIDDELDE DOELPUNTEN)\n")
print(head(league_analysis, 10))
```

Output:

```
COMPETITIEANALYSE (TOP 10 OP GEMIDDELDE DOELPUNTEN)
# A tibble: 10 × 6
  league_name      gemiddeld_doelpunten thuiswinst uitwinst gelijkspel wedstrijden
  <chr>              <dbl>         <dbl>    <dbl>    <dbl>         <int>
1 Netherlands Eredivisie      3.08      47.8     28.4     23.7          2448
2 Switzerland Super League    2.93      45.7     30.0     24.3          1422
3 Germany 1. Bundesliga      2.90      45.2     30.4     24.4          2448
4 Belgium Jupiler League      2.80      46.9     28.5     24.6          1728
5 Spain LIGA BBVA             2.77      48.8     28.0     23.2          3040
6 England Premier League      2.71      45.7     28.5     25.8          3040
7 Scotland Premier League     2.63      41.7     33.8     24.5          1824
8 Italy Serie A                2.62      46.6     27.0     26.4          3017
9 Portugal Liga ZON Sagres     2.53      44.2     29.8     26.0          2052
10 France Ligue 1              2.44      44.7     27.0     28.3          3040
```

Analyse:

De resultaten tonen duidelijke verschillen in scoringsintensiteit tussen competities.

- De Eredivisie is de meest doelpuntrijke competitie in deze dataset, met gemiddeld 3.08 doelpunten per wedstrijd.
- Ook competities zoals de Zwitserse Super League (2.93) en de Bundesliga (2.90) scoren hoog.
- Aan de andere kant behoren competities zoals de Ligue 1 (2.44) en de Primeira Liga (2.53) tot de laagste gemiddelde doelpuntentotalen

Correlatiematrix tussen doelpuntgerelateerde variabelen

Tot slot is de correlatie berekend tussen verschillende doelpuntgerelateerde variabelen om inzicht te krijgen in hun onderlinge samenhang.

Code:

```
# 8. Correlatiematrix tussen doelpuntgerelateerde variabelen
corr_data <- matches %>%
  select(home_team_goal, away_team_goal, total_goals, goal_difference) %>%
  drop_na()

cor_matrix <- cor(corr_data)
cat("\nCORRELATIEMATRIX TUSSEN DOELPUNTERELATEERDE VARIABELEN\n")
print(round(cor_matrix, 2))
```

Output:

```
CORRELATIEMATRIX TUSSEN DOELPUNTERELATEERDE VARIABELEN
      home_team_goal away_team_goal total_goals goal_difference
home_team_goal      1.00      -0.06      0.73      0.77
away_team_goal     -0.06      1.00      0.63     -0.69
total_goals         0.73      0.63      1.00      0.13
goal_difference      0.77     -0.69      0.13      1.00
```

Analyse:

De correlatiematrix toont duidelijke relaties tussen de doelpuntgerelateerde variabelen:

- Home_team_goal en total_goals hebben sterke positieve correlatie ($r = 0.73$). Dit is logisch: hoe meer het thuisteam scoort, hoe hoger het totaal aantal doelpunten per wedstrijd.
- Away_team_goal en total_goals zijn ook positief gecorreleerd ($r = 0.63$). Beide bijdragen immers aan het totaal aantal goals.
- Goal_difference correleert sterk positief met home_team_goal ($r = 0.77$). Hoe meer goals het thuisteam maakt, hoe groter de kans dat het doelpuntverschil in hun voordeel uitvalt.
- Er is een sterke negatieve correlatie tussen away_team_goal en goal_difference ($r = -0.69$). Dit is logisch: als het uitteam vaker scoort, wordt het thuisdoelpuntverschil kleiner.
- De correlatie tussen total_goals en goal_difference is relatief zwak ($r = 0.13$), en dus is het totale aantal doelpunten slechts beperkt gerelateerd aan welk team de wedstrijd domineert.

Samenvattend

De Exploratory Data Analysis biedt een helder inzicht in de structurele eigenschappen van de dataset. De belangrijkste bevindingen zijn:

- **Consistente trends:** Het gemiddeld aantal doelpunten blijft door de seizoenen heen relatief stabiel.
- **Thuisvoordeel:** Thuisteams scoren vaker en winnen aanzienlijk meer wedstrijden dan uitteams.
- **Invloed van speelstijl:** Meer aanvallende teamattributes tonen een duidelijke samenhang met een hoger aantal doelpunten.
- **Competitieveverschillen:** Het aantal doelpunten verschilt per competitie, wat aansluit bij bekende nationale speelstijlen.
- **Sterke relaties tussen variabelen:** Positieve correlaties tussen thuisdoelpunten en totaal aantal doelpunten bevestigen de onderlinge afhankelijkheid.

Deze resultaten vormen de analytische basis voor de volgende stap: Data Visualisatie, waarin de patronen visueel worden weergegeven voor verdere interpretatie en presentatie.

Visualisations

Na de data-acquisitie, preprocessing en Exploratory Data Analysis is in de laatste stap van de technische implementatie de nadruk gelegd op het visualiseren van patronen in de dataset. Waar de EDA zich vooral richtte op numerieke samenvattingen en tekstuele interpretaties, heeft het script `visualisations.R` deze inzichten vertaald naar grafieken en tabellen die de resultaten visueel en intuïtief begrijpelijk maken.

De visualisaties zijn volledig gebaseerd op de opgeschoonde dataset `clean_data.RData` en sluiten direct aan op de analyses uit de EDA. Het doel is niet alleen om trends te bevestigen, maar ook om verschillen tussen competities, teams en speelstijlen duidelijk in beeld te brengen.

Technische keuzes

Voor de visualisaties zijn de volgende R-packages gebruikt:

- **ggplot2** - hoofdtool voor het maken van lijnplots, staafdiagrammen en boxplots.
- **dplyr** en **tidyr** - voor het groeperen, aggregeren en voorbereiden van data voor elke grafiek.
- **corrplot** - voor het visualiseren van correlatiematrices als heatmap.
- **reshape2** - voor eventueel herschikken van data, indien nodig.
- **gridExtra** - bedoeld om meerdere plots te combineren

In alle ggplot-figuren wordt consequent `theme_minimal()` toegepast om de nadruk op de data te leggen, en worden aslabels en legends expliciet benoemd zodat iedere grafiek zonder extra uitleg te interpreteren is. Daarnaast worden seizoenen op de x-as vaak schuin geplot (`angle = 45`) om leesbaarheid te vergroten.

Lijnplots: trends in doelpunten over seizoenen

De eerste groep visualisaties richt zich op de ontwikkeling van doelpunten door de tijd.

Gemiddeld aantal doelpunten per seizoen

Om inzicht te krijgen in het verschil tussen thuis- en uitprestaties is per seizoen het gemiddelde aantal doelpunten berekend voor zowel thuis- als uitteams. Hiervoor is de dataset `matches` gegroepeerd op seizoen en zijn de gemiddelden van `home_team_goal` en `away_team_goal` bepaald.


```
season_goals <- matches %>%  
  group_by(season) %>%  
  summarise(  
    avg_home_goals = mean(home_team_goal, na.rm = TRUE),  
    avg_away_goals = mean(away_team_goal, na.rm = TRUE)  
  )
```

De resulterende samenvatting is gevisualiseerd met een lijnplot waarin de ontwikkeling van beide gemiddelden door de tijd wordt weergegeven. Het gemiddeld aantal thuisdoelpunten wordt getoond met een doorgetrokken lijn, terwijl het gemiddelde aantal uitdoelpunten wordt

weergegeven met een gestreepte lijn. Om de exacte waarden per seizoen beter af te kunnen lezen, zijn op beide lijnen punten toegevoegd. Daarnaast is de y-as fijn geschaald met stappen van 0.1 doelpunt, waardoor ook kleine verschillen tussen thuis- en uitdoelpunten duidelijk zichtbaar worden. De seizoenen op de x-as zijn schuin weergegeven om overlap te voorkomen en leesbaarheid te vergroten.

```
ggplot(season_goals, aes(x = season, group = 1)) +  
  geom_line(aes(y = avg_home_goals, color = "Thuis"),  
            linewidth = 1.3, linetype = "solid") +  
  geom_line(aes(y = avg_away_goals, color = "Uit"),  
            linewidth = 1.3, linetype = "dashed") +  
  
  geom_point(aes(y = avg_home_goals, color = "Thuis"), size = 2.5) +  
  geom_point(aes(y = avg_away_goals, color = "Uit"), size = 2.5) +  
  
  scale_y_continuous(  
    breaks = seq(  
      floor(min(c(season_goals$avg_home_goals,  
                  season_goals$avg_away_goals), na.rm = TRUE) * 10) / 10,  
      ceiling(max(c(season_goals$avg_home_goals,  
                    season_goals$avg_away_goals), na.rm = TRUE) * 10) / 10,  
      by = 0.1  
    )  
  ) +  
  
  labs(  
    title = "Gemiddeld aantal doelpunten per seizoen (Thuis vs Uit)",  
    x = "Seizoen",  
    y = "Gemiddeld aantal doelpunten",  
    color = "Legenda"  
  ) +  
  
  theme_minimal() +  
  theme(  
    axis.text.x = element_text(angle = 45, hjust = 1),  
    panel.grid.major.y = element_line(color = "grey85")  
  )
```

De visualisatie laat zien dat het gemiddelde aantal thuisdoelpunten in vrijwel alle seizoenen hoger ligt dan het gemiddelde aantal uitdoelpunten. Dit wijst op een consistent thuisvoordeel binnen de competitie. Tegelijkertijd maakt de grafiek inzichtelijk hoe dit verschil zich door de seizoenen heen ontwikkelt en of er sprake is van trends of schommelingen in scoringspatronen.



Gemiddeld aantal doelpunten per wedstrijd per seizoen en competitie

Om verschillen in scoringsniveau tussen competities en seizoenen inzichtelijk te maken, is per seizoen en competitie het gemiddelde aantal doelpunten per wedstrijd berekend. Hiervoor is de dataset matches gegroepeerd op season en league_name, waarna het gemiddelde van het totaal aantal doelpunten per wedstrijd (total_goals) is bepaald.

```
comp_season_goals <- matches %>%
  group_by(season, league_name) %>%
  summarise(
    avg_goals_per_match = mean(total_goals, na.rm = TRUE),
    .groups = "drop"
  )
```


De resultaten zijn gevisualiseerd met een lijnplot waarin elke competitie wordt weergegeven in een apart facet. Binnen elk facet toont een lijn de ontwikkeling van het gemiddelde aantal doelpunten per wedstrijd door de tijd, terwijl punten de afzonderlijke seizoenswaarden markeren. In tegenstelling tot eerdere visualisaties is hier gekozen voor vaste y-assen (scales = "fixed"), zodat de absolute niveaus van doelpunten tussen competities direct met elkaar vergeleken kunnen worden.


```
ggplot(comp_season_goals, aes(x = season, y = avg_goals_per_match, group = 1)) +
  geom_line(color = "blue", linewidth = 1) +
  geom_point(color = "red", size = 1.5) +
  facet_wrap(~ league_name, scales = "fixed") +

  labs(
    title = "Gemiddeld aantal doelpunten per wedstrijd per seizoen en competitie",
    subtitle = "Gemiddelde van thuis- en uitdoelpunten per wedstrijd",
    x = "Seizoen",
    y = "Gemiddeld aantal doelpunten per wedstrijd"
  ) +

  theme_minimal() +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1)
  )
)
```

Deze visualisatie maakt het mogelijk om zowel trends binnen individuele competities als verschillen tussen competities te analyseren. Doordat alle facetten dezelfde y-as gebruiken, wordt duidelijk welke competities structureel meer doelpunten per wedstrijd scoren en in hoeverre dit scoringsniveau door de seizoenen heen verandert. De grafiek biedt daarmee een overzichtelijke en vergelijkbare weergave van scoringspatronen op competitieniveau.



Heatmaps: intensiteit en patronen per competitie en in teamattributes

Heatmaps worden gebruikt voor twee soorten analyses: doelpunten per competitie en correlaties tussen teamattributes

Heatmap van gemiddelde doelpunten per seizoen en competitie


Om verschillen in scoringsniveau tussen competities en seizoenen op een compacte en vergelijkbare manier weer te geven, is een heatmap opgesteld waarin per seizoen en competitie het gemiddelde aantal doelpunten per wedstrijd wordt weergegeven. Hiervoor is de dataset matches gegroepeerd op season en league_name, waarna het gemiddelde van total_goals is berekend.

```
season_league_goals <- matches %>%  
  group_by(season, league_name) %>%  
  summarise(avg_goals = mean(total_goals, na.rm = TRUE)) %>%  
  ungroup()
```

De samengevatte gegevens zijn gevisualiseerd met behulp van een heatmap, waarbij elk vakje een combinatie van seizoen en competitie vertegenwoordigt. De kleur van het vakje geeft het gemiddelde aantal doelpunten per wedstrijd aan: lichtere kleuren (lichtgeel) duiden op een lager scoringsgemiddelde, terwijl donkerdere kleuren (rood) wijzen op een hoger aantal doelpunten.

```
ggplot(season_league_goals, aes(x = season, y = league_name, fill = avg_goals)) +  
  geom_tile(color = "white") +  
  scale_fill_gradient(low = "lightyellow", high = "red", name = "Gem. doelpunten") +  
  labs(  
    title = "Heatmap van gemiddelde doelpunten per seizoen en competitie",  
    x = "Seizoen", y = "Competitie"  
  ) +  
  theme_minimal() +  
  theme(  
    axis.text.x = element_text(angle = 45, hjust = 1),  
    axis.text.y = element_text(size = 8)  
  )
```

Deze visualisatie maakt het mogelijk om in een oogopslag patronen en verschillen tussen competities en seizoenen te herkennen. Verticale kleurveranderingen laten zien hoe het scoringsniveau binnen een competitie door de tijd verandert, terwijl horizontale verschillen inzicht geven in welke competities structureel meer of minder doelpunten per wedstrijd kennen. De heatmap vormt daarmee een effectief aanvullend instrument naast lijnplots, omdat zowel trends als relatieve niveaus tegelijk zichtbaar worden



Heatmap van correlaties tussen teamattributen

Om inzicht te krijgen in onderlinge samenhang tussen verschillende teamattributen is een correlatieanalyse uitgevoerd. Hierbij is gebruikgemaakt van de dataset `team_attr`, waarin per team verschillende spelkenmerken zijn vastgelegd. Voor deze analyse is een selectie gemaakt van zes relevante attributen die betrekking hebben op opbouw, kanscreatie en defensief gedrag.

```
team_attr_corr <- team_attr %>%
  select(buildUpPlaySpeed, buildUpPlayPassing,
         chanceCreationPassing, chanceCreationShooting,
         defencePressure, defenceAggression) %>%
  cor(use = "complete.obs")
```


De correlatiematrix is vervolgens gevisualiseerd met behulp van een correlatieplot. In deze visualisatie worden alleen de waarden in de bovenste driehoek van de matrix getoond om

herhaling te voorkomen. De kleurintensiteit geeft de sterkte van de correlatie weer: hoe sterker de kleur, hoe sterker de positieve of negatieve samenhang tussen twee attributes.

```
corrplot(team_attr_corr, method = "color", type = "upper",  
         title = "Correlatie tussen teamattributes",  
         tl.col = "black", tl.srt = 45,  
         mar = c(0, 0, 3, 0))
```

Deze visualisatie maakt het mogelijk om snel te identificeren welke teamattributes sterk met elkaar samenhangen. Zo kan bijvoorbeeld worden onderzocht of teams met een hogere opbouwsnelheid ook vaker kenmerken vertonen van directer spel of agressiever defensief gedrag.

Correlatie tussen teamattributes



Ranglijsten: barplots voor topteams en topspelers

Om individuele prestaties in kaart te brengen, zijn barplots gemaakt voor zowel teams als spelers.

Top 10 teams met het hoogste gemiddelde aantal doelpunten per wedstrijd

Om te bepalen welke teams over de gehele dataset het meest productief zijn in termen van doelpunten, is per team het gemiddelde aantal doelpunten per wedstrijd berekend. Omdat teams zowel thuis- als uitwedstrijden spelen, zijn eerst alle doelpunten per team samengevoegd door de thuis- en uitdoelpunten te combineren.

```
team_match_goals <- bind_rows(  
  matches_raw %>%  
    transmute(team_api_id = home_team_api_id, goals = home_team_goal),  
  matches_raw %>%  
    transmute(team_api_id = away_team_api_id, goals = away_team_goal)  
)
```


Vervolgens is per team het gemiddelde aantal doelpunten berekend. Deze waarden zijn gekoppeld aan de teamnamen uit de teams_raw dataset, waarna de teams zijn gesorteerd op hun scoringsgemiddelde en de top 10 is geselecteerd.

```
team_avg_goals <- team_match_goals %>%  
  group_by(team_api_id) %>%  
  summarise(avg_goals = mean(goals, na.rm = TRUE), .groups = "drop")  
  
top_10_teams <- team_avg_goals %>%  
  left_join(  
    teams_raw %>% select(team_api_id, team_long_name),  
    by = "team_api_id"  
  ) %>%  
  filter(!is.na(team_long_name)) %>%  
  arrange(desc(avg_goals)) %>%  
  slice_head(n = 10)
```

De resultaten zijn gevisualiseerd met een horizontale barplot. Door de teams op de y-as te sorteren op basis van hun gemiddelde aantal doelpunten, ontstaat een overzichtelijke ranglijst waarin direct zichtbaar is welke teams het meest scorend zijn. De horizontale orientatie (coord_flip) verbeterd de leesbaarheid van de teamnamen.

```
ggplot(top_10_teams, aes(x = reorder(team_long_name, avg_goals), y = avg_goals)) +
  geom_bar(stat = "identity", fill = "orange") +
  coord_flip() +
  labs(
    title = "Top 10 teams met hoogste gemiddelde aantal doelpunten per wedstrijd",
    x = "Team",
    y = "Gemiddeld aantal doelpunten"
  ) +
  theme_minimal()
```

Deze visualisatie laat zien welke teams structureel een hoog scoringsgemiddelde behalen, ongeacht of zij thuis of uit spelen. De barplot biedt daarmee een duidelijke vergelijking van aanvallende effectiviteit tussen teams en vormt een waardevolle aanvulling op de eerdere analyses van doelpunten per seizoen en competitie.



Top 10 spelers op basis van gemiddelde rating

Om inzicht te krijgen in welke spelers over de tijd de hoogste prestaties leveren, is per speler het gemiddelde van de overall rating berekend. Hiervoor is gebruikgemaakt van de dataset `player_attr`, waarin per speler meerdere metingen van de `overall_rating` zijn vastgelegd.

```
player_ratings <- player_attr %>%  
  group_by(player_api_id) %>%  
  summarise(  
    avg_rating = mean(overall_rating, na.rm = TRUE),  
    .groups = "drop"  
  )
```

De berekende gemiddelde ratings zijn vervolgens gekoppeld aan de bijbehorende spelersnamen uit de `players_raw` dataset. Spelers zonder naam zijn uit de analyse gefilterd. Daarna zijn de spelers gesorteerd op hun gemiddelde rating en is de top 10 geselecteerd.


```
top_10_players <- player_ratings %>%  
  left_join(  
    players_raw %>% select(player_api_id, player_name),  
    by = "player_api_id"  
  ) %>%  
  filter(!is.na(player_name)) %>%  
  arrange(desc(avg_rating)) %>%  
  slice_head(n = 10)
```

De resultaten zijn gevisualiseerd met een horizontale barplot, waarbij de spelers zijn gerangschikt op basis van hun gemiddelde rating. Door gebruik te maken van `coord_flip` worden de spelersnamen overzichtelijk weergegeven en is eenvoudig te zien welke spelers het hoogste gemiddelde beoordelingsniveau hebben.

```
ggplot(top_10_players, aes(x = reorder(player_name, avg_rating), y = avg_rating)) +  
  geom_bar(stat = "identity", fill = "purple") +  
  coord_flip() +  
  labs(  
    title = "Top 10 spelers op gemiddelde rating",  
    x = "Speler",  
    y = "Gemiddelde rating"  
  ) +  
  theme_minimal()
```

Deze visualisatie biedt een duidelijk overzicht van de spelers die structureel hoog worden beoordeeld en kan worden gebruikt als basis voor verdere analyses.

Top 10 spelers op gemiddelde rating




Boxplot: Totaal aantal doelpunten per wedstrijd per competitie

Om inzicht te krijgen in spreiding en verdeling van het totaal aantal doelpunten per wedstrijd binnen verschillende competities, is een boxplot opgesteld. In deze analyse wordt gebruikgemaakt van de variabele `total_goals`, die het totaal aantal doelpunten in een wedstrijd (thuis- en uitdoelpunten samen) weergeeft, uitgesplitst per competitie (`league_name`).

```
ggplot(matches, aes(x = league_name, y = total_goals)) +  
  geom_boxplot(fill = "lightgreen") +  
  labs(  
    title = "Boxplot van totaal aantal doelpunten per wedstrijd per competitie",  
    x = "Competitie",  
    y = "Totaal aantal doelpunten per wedstrijd"  
  ) +  
  theme_minimal() +  
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

De boxplot toont per competitie de mediaan, het interkwartielbereik en eventuele uitschieters in het aantal doelpunten per wedstrijd. Hierdoor wordt niet alleen zichtbaar hoeveel er gemiddeld wordt gescoord, maar ook hoe consistent of juist variabel het scoringspatroon binnen een competitie is. Competities met een smalle box vertonen relatief stabiele aantallen doelpunten, terwijl bredere boxen en veel uitschieters wijzen op grotere variatie tussen wedstrijden.

Deze visualisatie biedt een waardevolle aanvulling op de eerdere analyses van gemiddelde doelpunten per seizoen en competitie, doordat zij de volledige verdeling van doelpunten inzichtelijk maakt in plaats van alleen samenvattende statistieken.



Scatterplot: Relatie tussen gemiddelde thuis- en uitdoelpunten per team

Om goed te onderzoeken of teams die sterk presteren in thuiswedstrijden ook relatief goed scoren in uitwedstrijden, is per team het gemiddelde aantal thuis- en uitdoelpunten per wedstrijd berekend. Hiervoor zijn de thuis- en uitwedstrijden afzonderlijk geanalyseerd op basis van de dataset matches_raw.

```

home_goals <- matches_raw %>%
  group_by(team_api_id = home_team_api_id) %>%
  summarise(
    avg_home_goals = mean(home_team_goal, na.rm = TRUE),
    .groups = "drop"
  )

away_goals <- matches_raw %>%
  group_by(team_api_id = away_team_api_id) %>%
  summarise(
    avg_away_goals = mean(away_team_goal, na.rm = TRUE),
    .groups = "drop"
  )

```

De berekende gemiddelden zijn vervolgens samengevoegd tot een dataset en gekoppeld aan de bijbehorende teamnamen uit teams_raw. Teams zonder geldige naam zijn hierbij gefilterd.

```

team_perf <- home_goals %>%
  left_join(away_goals, by = "team_api_id") %>%
  left_join(
    teams_raw %>% select(team_api_id, team_long_name),
    by = "team_api_id"
  ) %>%
  filter(!is.na(team_long_name))

```


De relatie tussen het gemiddelde aantal thuis- en uitdoelpunten per team is gevisualiseerd met een scatterplot. Elk punt vertegenwoordigt een team, waarbij de x-as het gemiddelde aantal thuisdoelpunten weergeeft en de y-as het gemiddelde aantal uitdoelpunten. Daarnaast is een lineaire regressielijn toegevoegd om de algemene trend tussen beide variabelen inzichtelijk te maken.

```

ggplot(team_perf, aes(x = avg_home_goals, y = avg_away_goals)) +
  geom_point(color = "steelblue", alpha = 0.6, size = 3) +
  geom_smooth(method = "lm", se = FALSE, color = "darkred") +
  labs(
    title = "Relatie tussen gemiddelde thuis- en uitdoelpunten per team",
    x = "Gemiddeld aantal thuisdoelpunten per wedstrijd",
    y = "Gemiddeld aantal uitdoelpunten per wedstrijd"
  ) +
  theme_minimal()

```

Deze visualisatie laat zien in hoeverre er een positieve samenhang bestaat tussen thuis- en uitprestaties van teams. Een stijgende regressielijn wijst erop dat teams die thuis veel scoren, gemiddeld genomen ook vaker doelpunten maken in uitwedstrijden. Tegelijkertijd maakt de spreiding van de punten zichtbaar dat sommige teams een relatief sterk thuisvoordeel hebben, terwijl andere teams consistentere presteren ongeacht de speellocatie.



Samenvattend

In dit hoofdstuk zijn verschillende visualisaties gebruikt om patronen en relaties in wedstrijd-, team- en spelersdata inzichtelijk te maken. Door gebruik te maken van lijnplots, barplots, boxplots, scatterplots, heatmaps en correlatieplots zijn zowel trends door de tijd als verschillen tussen teams, competities en spelers geanalyseerd.

De lijnplots toonden aan dat het gemiddelde aantal doelpunten per seizoen relatief stabiel blijft, maar dat er duidelijke verschillen bestaan tussen competities. Daarnaast werd zichtbaar dat teams structureel meer doelpunten scoren in thuiswedstrijden dan in uitwedstrijden, wat wijst op een consistent thuisvoordeel. Facet-visualisaties per competitie maakten het mogelijk om trends binnen competities afzonderlijk te beoordelen en deze onderling te vergelijken.

Met behulp van boxplots werd duidelijk dat niet alleen de gemiddelden, maar ook de spreiding van het aantal doelpunten per wedstrijd per competitie verschilt. Sommige competities laten een grotere variatie en meer uitschieters zien, terwijl andere competities een consistenters scoringspatroon vertonen. De heatmapvisualisatie bood aanvullend inzicht door in één overzicht zowel seizoens- als competitieverschillen in scoringsniveau zichtbaar te maken.

Op team- en individueel niveau gaven barplots inzicht in de meest scorende teams en de hoogst gewaardeerde spelers. Deze visualisaties maakten duidelijk dat een beperkte groep teams en spelers structureel bovengemiddeld presteert. De scatterplot van gemiddelde thuis- en uitdoelpunten per team liet bovendien zien dat er een positieve relatie bestaat tussen prestaties in beide situaties, al verschilt de mate waarin teams afhankelijk zijn van thuisvoordeel.

Tot slot bood de correlatieplot van teamattributen inzicht in de onderlinge samenhang tussen speelstijleigenschappen, zoals opbouw, kanscreatie en defensief gedrag. Deze analyse vormt een brug naar mogelijke vervolgonderzoeken waarin prestaties worden gekoppeld aan speelstijl.

Gezamenlijk geven de visualisaties een samenhangend beeld van scoringspatronen en prestaties binnen het voetbal, waarbij zowel macro-trends (seizoenen en competities) als micro-niveau verschillen (teams en spelers) inzichtelijk zijn gemaakt. Ze vormen daarmee een sterke visuele ondersteuning van de exploratory data analysis en bieden een solide basis voor verdere, meer verklarende analyses.

Results & Evaluation

Results

In dit hoofdstuk worden de belangrijkste resultaten van het project gepresenteerd en geëvalueerd. De focus ligt hierbij op de inzichten die zijn verkregen uit de Exploratory Data Analysis en de daaropvolgende visualisaties. De resultaten worden besproken op verschillende niveaus: wedstrijdniveau, competitieniveau, teamniveau, en spelersniveau.

Wedstrijdniveau: doelpunten en resultaatverdeling

De analyses op wedstrijdniveau laten een duidelijk en consistent patroon zien in het scoringsgedrag binnen Europese voetbalcompetities. Het gemiddeld aantal doelpunten per wedstrijd ligt rond de 2.7, wat wijst op een overwegend aanvallend karakter van het moderne voetbal. De mediaan bevestigt dat de meeste wedstrijden eindigen met twee tot drie doelpunten.

Een belangrijk resultaat is het duidelijk aantoonbare thuisvoordeel. Thuis teams scoren gemiddeld meer doelpunten dan uit teams en winnen bijna de helft van alle wedstrijden. Dit patroon komt niet alleen tot uiting in de numerieke samenvattingen, maar wordt ook visueel bevestigd in de lijnplots waarin thuis- en uitdoelpunten per seizoen naast elkaar zijn weergegeven. De consistent hogere lijn voor thuisdoelpunten over alle seizoenen onderstreept dat dit geen toeval of seizoensgebonden effect is, maar een structureel kenmerk van de dataset.

Trends door de tijd: stabiliteit en seizoensontwikkeling

De visualisaties van doelpunten per seizoen tonen aan dat het gemiddelde aantal doelpunten door de jaren heen relatief stabiel blijft. Hoewel kleine schommelingen zichtbaar zijn, ontbreken sterke stijgende of dalende trends. Dit wijst erop dat het algemene scoringsniveau binnen Europese competities gedurende de onderzochte periode weinig structurele verandering heeft doorgemaakt.

Door het gebruik van facet-visualisaties per competitie wordt zichtbaar dat deze stabiliteit ook geldt binnen afzonderlijke leagues. Sommige competities kennen licht fluctuerende patronen, maar over het geheel genomen blijven de verschillen tussen competities consistenten dan de verschillen binnen een competitie over de tijd.

Competitieniveau: verschillen in speelstijl en scoringsintensiteit

Een van de meest duidelijke resultaten van de analyses is het bestaan van structurele verschillen tussen competities. Zowel de tabellen als de visualisaties laten zien dat sommige competities structureel meer doelpunten per wedstrijd kennen dan andere.

Competities zoals de Nederlandse Eredivisie, de Zwitserse Super League en de Duitse Bundesliga behoren tot de meest doelpuntrijke leagues in de dataset. Aan de andere kant laten competities zoals de Franse Ligue 1 en de Portugese Primeira Liga lagere gemiddelde doelpunten zien. De heatmap van gemiddelde doelpunten per seizoen en competitie maakt deze verschillen in een oogopslag zichtbaar en benadrukt dat deze patronen consistent zijn over meerdere seizoenen.

De boxplots per competitie laten aanvullend zien dat niet alleen het gemiddelde verschilt, maar ook de spreiding van doelpunten. Sommige competities vertonen een grotere variabiliteit en meer uitschieters, wat kan wijzen op minder voorspelbare wedstrijd verlopen.

Teamniveau: prestaties en speelstijl

Op teamniveau bieden de resultaten inzicht in verschillen in aanvallende effectiviteit en speelstijl. De ranglijsten van teams met het hoogste gemiddelde aantal doelpunten tonen aan dat een beperkte groep teams structureel bovengemiddeld presteert. Deze teams scoren consistent hoog, ongeacht seizoen of tegenstander, wat wijst op stabiele aanvalskracht.

De koppeling van teamattributes aan wedstrijdprestaties maakt het mogelijk om speelstijlkenmerken te relateren aan scoringsgedrag. De scatterplots en correlatieanalyses laten zien dat bepaalde aanvallende attributes, zoals build-up play speed en kanscreatie, samenhangen met hogere aantallen doelpunten. Tegelijkertijd blijkt dat verdedigende eigenschappen niet altijd sterk correleren met aanvallende prestaties, wat suggereert dat teams verschillende tactische profielen kunnen hebben om succes te behalen.

Spelersniveau: individuele kwaliteit

Op individueel niveau bieden de barplots van spelersrating inzicht in welke spelers over meerdere seizoenen structureel hoog worden beoordeeld. De top 10 spelers op basis van gemiddelde rating bestaat uit bekende spelers die consistent presteren. Deze visualisaties tonen niet alleen individuele kwaliteit, maar illustreren ook hoe spelersdata gebruikt kan worden om prestaties over tijd te vergelijken, in plaats van momentopnames te analyseren.

Evaluation

De resultaten van dit project laten zien dat de gekozen aanpak geschikt is voor het analyseren van complexe voetbaldata. Door een gestructureerde preprocessing, gevolgd door EDA en visualisaties, zijn zowel verwachte als minder voor de hand liggende patronen zichtbaar gemaakt.

Een sterke kant van de resultaten is de consistentie tussen numerieke analyses en visualisaties. Patronen zoals het thuisvoordeel, competitieverschillen en stabiele scoringsniveaus worden zowel statistisch als visueel bevestigd. Dit verhoogt de betrouwbaarheid van de bevindingen en maakt de analyses toegankelijk voor een breder publiek.

Daarnaast bieden de visualisaties duidelijke meerwaarde ten opzichte van tabellen. Met name heatmaps, boxplots en facet-visualisaties maken het mogelijk om meerdere dimensies tegelijk te analyseren, zoals tijd, competitie en spreiding van prestaties.

Tegelijkertijd kent de analyse ook beperkingen. De resultaten beschrijven vooral wat er in de data te zien is en laten verbanden en patronen zien, maar geven geen uitleg over waarom deze patronen ontstaan. Daarnaast is in dit project voornamelijk gewerkt met gemiddelden. Hierdoor blijven verschillen tussen individuele wedstrijden en andere belangrijke omstandigheden, zoals de sterkte van de tegenstander of de wedstrijdssituatie, buiten beschouwing.

Desondanks vormt dit hoofdstuk een solide evaluatie van wat met de huidige data en methoden bereikt kan worden. De resultaten bieden een duidelijke basis voor verdere interpretatie, verdieping en uitbreiding, die in de volgende hoofdstukken verder zullen worden besproken.

Discussion & Future Work

Discussion

In dit hoofdstuk reflecteer ik op de resultaten van de Exploratory Data Analysis en de visualisaties. Het doel van deze discussie is om de betekenis van de gevonden patronen te duiden, de gemaakte keuzes kritisch te beschouwen en de beperkingen van het huidige project te benoemen. Hierbij trek ik bewust nog geen conclusies, maar plaats ik de resultaten in de juiste context.

Interpretatie van de resultaten

De uitgevoerde analyses laten zien dat beschrijvende statistiek en visualisatie zeer geschikt zijn om patronen in voetbaldata inzichtelijk te maken. Patronen zoals het thuisvoordeel, verschillen tussen competities en variatie in scoringsniveau komen consistent terug in zowel tabellen als grafieken. Het feit dat dezelfde trends zichtbaar zijn via meerdere analysetechnieken, vergroot mijn vertrouwen in de robuustheid van deze observaties.

Tegelijkertijd is het belangrijk om te benadrukken dat dit project een exploratief karakter heeft. De resultaten tonen verbanden en trends, maar verklaren niet automatisch de onderliggende oorzaken. Bijvoorbeeld: een relatie tussen teamattributen en doelpunten betekent niet dat een bepaalde speelstijl direct leidt tot meer goals. Andere factoren, zoals teamkwaliteit, tegenstanders en competitieniveau, kunnen hierin eveneens een rol spelen.

Interpretatie van correlaties

In de EDA en visualisaties heb ik gebruikgemaakt van correlatieanalyses om mogelijke verbanden tussen variabelen te verkennen. Deze correlaties bieden waardevolle eerste inzichten, maar hebben duidelijke beperkingen:

- De correlaties zijn gebaseerd op gemiddelden per team, waardoor variatie binnen seizoenen of tactische veranderingen door de tijd niet volledig zichtbaar zijn.
- Contextuele factoren, zoals de sterkte van de tegenstander of wedstrijdsituaties, worden niet meegenomen in deze eenvoudige correlaties

Daarom beschouw ik de correlatieresultaten vooral als richtinggevend: ze helpen bij het identificeren van interessante variabelen voor mogelijke vervolganalyses, maar zijn geen bewijs voor causale verbanden.

Methodologische keuzes en beperkingen

Tijdens de preprocessing en analyse heb ik bewust keuzes gemaakt om de dataset beheersbaar en consistent te houden. Deze keuzes hebben echter invloed op de interpretatie van de resultaten:

- **Mediaan-imputatie van missende waarden**
Door missende numerieke waarden te vervangen door de mediaan blijven datasets volledig en stabiel. Tegelijkertijd kan deze aanpak variatie verminderen en subtiële verschillen afvlakken, wat invloed kan hebben op gemiddelden en correlaties.

- **Koppeling van teamattributes aan alleen het thuisspelende team**

In de huidige implementatie zijn teamattributes gekoppeld aan het thuisspelende team. Hierdoor vertegenwoordigen analyses met teamattributes vooral het perspectief van de thuisploeg, terwijl de speelstijl van het uitteam buiten beschouwing blijft.

- **Focus op doelpunten als kernprestatie-indicator**

Doelpunten vormen een duidelijke en directe maat voor prestaties, maar zijn relatief schaars en gevoelig voor toeval. Andere prestatie-indicatoren, zoals schoten, balbezit en kaarten, zijn in deze fase niet volledig meegenomen en kunnen aanvullende verklaringskracht bieden.

Validiteit en betrouwbaarheid

De interne validiteit van het project is sterk, omdat de volledige analyse reproduceerbaar is via een duidelijke workflow: data-acquisitie, preprocessing, EDA en visualisatie. Patronen worden bovendien bevestigd via meerdere analyses en grafieken

De externe validiteit is beperkter. De resultaten gelden specifiek voor de gebruikte dataset, competities en onderzochte seizoenen. Veranderingen in spelregels, tactieken en teamsterkte door de tijd kunnen betekenen dat patronen niet automatisch generaliseerbaar zijn naar andere perioden of datasets.

Future Work

Hoewel het huidige project een solide basis biedt, zijn er meerdere uitbreidingen mogelijk om de analyses verder te verdiepen en te versterken

Uitbreiding van features

Een logische volgende stap is het uitbreiden van de gebruikte variabelen. In een vervolg kan ik aanvullende wedstrijdstatistieken opnemen, zoals:

- totaal aantal schoten en schoten op doel,
- balbezit en passnauwkeurigheid,
- kaarten en overtredingen.

Hiermee kan niet alleen het eindresultaat, maar ook het spelverloop beter worden geanalyseerd.

Verbeterde koppeling van teaminformatie

De huidige analyses kunnen worden verfijnd door:

- teamattributes ook aan het uit spelende team te koppelen,
- teamattributes te koppelen op basis van datum, zodat verandering in speelstijl door de tijd zichtbaar worden.

Dit zou de analyses realistischer maken.

Uitbreiding van visualisaties

Hoewel de huidige visualisaties informatief zijn, kan het project worden uitgebreid met:

- aanvullende distributie plots
- gecombineerde visualisaties waarin meerdere prestatie-indicatoren samenkomen.

Van exploratief naar voorspellend

Op langere termijn kan dit project worden uitgebreid richting voorspellende modellen, zoals:

- regressiemodellen voor doelpunten
- classificatiemodellen voor wedstrijdresultaten

Hiermee kan de stap worden gezet van beschrijvende analyse naar modelmatige voorspelling

Conclusion

In dit project heb ik onderzocht hoe voetbaldata uit de European Soccer Database kan worden geanalyseerd en geïnterpreteerd met behulp van R. Het doel was om trends, patronen en relaties binnen wedstrijd datasets inzichtelijk te maken door middel van een gestructureerd data-analyseproces. Gedurende het project heb ik alle kernfasen van een data science-workflow doorlopen: data-acquisitie, preprocessing, exploratory data analysis en visualisatie.

Allereerst heb ik de ruwe SQLite-database succesvol geïmporteerd en omgezet naar bruikbare R-dataframes. Door middel van gerichte preprocessing heb ik de dataset opgeschoond, relevante variabelen geselecteerd en verrijkt met nieuwe kenmerken zoals doelpuntverschil, wedstrijdresultaat en samenvattende team- en spelersstatistieken. Deze stap was essentieel om een consistente en analyse klare dataset te creëren.

De Exploratory Data Analysis gaf mij een goed overzicht van de structuur en eigenschappen van de data. ik heb inzicht gekregen in algemene wedstrijdstatistieken, de verdeling van wedstrijdresultaten en verschillen tussen competities en seizoenen. Daarnaast heb ik relaties tussen variabelen onderzocht, zoals het verband tussen thuis- en uitdoelpunten en de samenhang tussen teamattributen. Deze analyses boden een solide basis voor verdere interpretatie zonder direct conclusies te forceren.

Met behulp van visualisaties heb ik deze patronen vervolgens op een overzichtelijke en intuïtieve manier gepresenteerd. Lijnplots, boxplots, heatmaps en scatterplots maakten trends door de tijd, verschillen tussen competities en mogelijke verbanden tussen speelstijl en prestaties duidelijk zichtbaar. De visualisaties vormden daarmee een belangrijk hulpmiddel om de resultaten niet alleen te analyseren, maar ook begrijpelijk te communiceren.

Terugkijkend heeft dit project mij laten zien hoe krachtig gestructureerde data-analyse kan zijn binnen de context van sportdata. ik heb niet alleen technische vaardigheden in R verder ontwikkeld, maar ook geleerd hoe belangrijk het is om data zorgvuldig voor te bereiden, resultaten kritisch te interpreteren en bevindingen helder te presenteren. Het project laat zien dat zelfs complexe en omvangrijke datasets op een overzichtelijke manier kunnen worden geanalyseerd wanneer een duidelijke methodologische aanpak wordt gevolgd.

Tot slot vormt dit project een sterke basis voor verdere verdieping. De opgebouwde workflow en analyses zijn goed uitbreidbaar en bieden mogelijkheden voor meer geavanceerde modellen of diepgaandere analyses in toekomstig werk. Daarmee sluit dit project niet alleen af als een afgeronde analyse, maar ook als een waardevolle leerervaring binnen data science en sportanalyse.