

Voetbal door de Lens van Data: Analyse en Visualisatie



Naam: Sven Bruning

Studentnummer: 5667259

Opleiding: Technische Informatica

Inleiding	3
Background & Objectives	4
Background	4
Objectives	4
Technical Design & Implementation	5
Dataset & Database	5
Data-acquisitie & Preprocessing	8
Exploratory Data Analysis (EDA)	13

Inleiding

Voetbal is wereldwijd de populairste sport en genereert dagelijks grote hoeveelheden data. Statistieken zoals doelpunten, schoten op doel, balbezit, passes en kaarten worden verzameld en vastgelegd voor wedstrijden over de hele wereld. Deze gegevens bieden niet alleen inzicht in individuele teamprestaties, maar kunnen ook gebruikt worden om trends, patronen en strategische inzichten te ontdekken.

Hoewel veel data beschikbaar is, is het vaak een uitdaging om deze informatie op een overzichtelijke en zinvolle manier te analyseren. Onbewerkte datasets zijn moeilijk te interpreteren en vereisen gestructureerde methoden voor exploratie en visualisatie. Data-analyse biedt de mogelijkheid om voetbalstatistieken op een systematische manier te onderzoeken, verbanden te identificeren en overzichtelijke inzichten te creëren.

Dit project richt zich op het analyseren van voetbalstatistieken met R en RStudio, met als doel het ontdekken van trends, patronen en inzichten in wedstrijddatasets. Het project concentreert zich op drie kernactiviteiten van dat science:

1. **Data-acquisitie en preprocessing:** het verzamelen, opschonen en voorbereiden van de dataset voor analyse.
2. **Exploratory Data Analysis (EDA):** het verkennen van data om interessante statistische patronen te identificeren.
3. **Data Visualisatie:** het presenteren van analyses in grafieken en tabellen om de bevindingen inzichtelijk te maken.

Het project streeft ernaar een diepgaand inzicht te bieden in voetbaldata en laat zien hoe gestructureerde analyse en visualisatie kunnen bijdragen aan een beter begrip van wedstrijdprestaties.

De rest van dit verslag is als volgt opgebouwd: in Background & Objectives wordt de context en het doel van het project beschreven. In Technical Design & Implementation wordt de dataset, de analysemethoden en de implementatie in R besproken. In Results & Evaluation worden de belangrijkste bevindingen en grafische visualisaties gepresenteerd, en in Discussion & Future Work volgt een reflectie op de resultaten en suggesties voor toekomstige uitbreiding van het project.

Background & Objectives

Background

Voetbal genereert een grote hoeveelheid data per seizoen, zoals informatie over wedstrijden, teams, spelers en prestaties. Voor clubs, analisten en onderzoekers kan deze data waardevolle inzichten bieden in trends, strategieën en succesfactoren.

Voor dit project wordt gebruikgemaakt van de European Soccer Database (beschikbaar op Kaggle). Deze dataset bevat:

- **Wedstrijdgegevens:** datum, competitie, seizoen, doelpunten, schoten, balbezit, kaarten, uitslag.
- **Teamstatistieken:** teams, ranglijst, punten, doelpunten voor en tegen.
- **Spelersstatistieken:** goals, assists, speelminuten, positie, kaarten.

Deze dataset is geschikt om patronen en trends in wedstrijden, teams en spelers over meerdere seizoenen te onderzoeken.

Objectives

Het project heeft de volgende concrete doelstellingen:

1. Data-acquisitie en voorbereiding:
 - Downloaden van de dataset van Kaggle en importeren in RStudio.
 - Opschonen van de data: verwijderen van ontbrekende waarden in kritieke kolommen (zoals doelpunten of uitslagen), converteren van datatypes (bijv. datum naar Date, numerieke waarden), samenvoegen van gerelateerde tabellen (bijv. wedstrijd- en teamstatistieken)
2. Exploratory Data Analysis (EDA):
 - Onderzoeken van verdelingen van doelpunten, balbezit, schoten en kaarten.
 - Analyse van trends over seizoenen en competities.
 - Vergelijkingen tussen teams, zoals thuis- vs. uitprestaties.
 - Correlatieanalyse tussen statistieken, bijvoorbeeld schoten vs. doelpunten, balbezit vs. winstkans
3. Data Visualisatie:
 - Creëren van grafieken in R (ggplot2) om inzichten duidelijk te maken, bijvoorbeeld:
 - Lijnplots van gemiddelde doelpunten per seizoen per competitie.
 - Boxplots van schoten per team.
 - Heatmaps van correlaties tussen statistieken.
 - Tabellen met samenvattende statistieken per team of speler.
4. Interpretatie en conclusies:
 - Identificeren van belangrijke trends en factoren die succes beïnvloeden
 - Kritisch reflecteren op beperkingen van de dataset.
 - Voorstellen van mogelijke vervolgonderzoeken of uitbreidingen van de analyses

Technical Design & Implementation

Dataset & Database

Voor dit project wordt gebruikgemaakt van de European Soccer Database, een dataset die beschikbaar is gesteld op Kaggle. Deze dataset is opgebouwd als een SQLite database (database.sqlite) en bevat gegevens van meer dan 25.000 voetbalwedstrijden, 11.000 spelers, 300 teams en 2008-2016 seizoenen uit 11 Europese landen.

Alle tabellen in de database

1. Country

Bevat informatie over landen waarin competities plaatsvinden.

Belangrijke velden:

- `id` - unieke identificatie van het land
- `name` - naam van het land (bijv. "Spain")

2. League

Bevat informatie over competities in verschillende landen.

Belangrijke velden:

- `id` - unieke identificatie van de competitie
- `country_id` - koppeling naar Country
- `name` - naam van de competitie (bijv. "Germany 1. Bundesliga")

3. Match

Bevat informatie over individuele wedstrijden.

Belangrijke velden:

- `id` - unieke identificatie van de wedstrijd
- `season` - seizoen (bijv. "2013/2014")
- `date` - datum van de wedstrijd
- `home_team_api_id`, `away_team_api_id` - koppeling naar teams
- `home_team_goal`, `away_team_goal` - aantal doelpunten

4. Team

Bevat informatie over voetbalteams.

Belangrijke velden:

- `team_api_id` - unieke sleutel voor koppeling met Match
- `team_long_name` - volledige naam van het team
- `team_short_name` - afkorting

5. Team_Attributes

Bevat statistieken en speelstijl van teams over de tijd.

Belangrijke velden:

- `team_api_id` - koppeling naar Team
- `date` - datum van de meting
- `buildUpPlaySpeed` - snelheid van de opbouw
- `defencePressure` - verdedigingsdruk

6. Player

Bevat informatie over spelers.

Belangrijke velden:

- `player_api_id` - unieke speler-ID
- `player_name` - naam van de speler
- `birthday` - geboortedatum
- `height` - lengte (cm)
- `weight` - gewicht (lbs)

7. Player_Attributes

Bevat statistieken en vaardigheden van spelers door de tijd heen.

Belangrijke velden:

- `player_api_id` - koppeling naar Player
- `date` - datum van meting
- `overall_rating` - algemene rating
- `potential` - potentieel
- `preferred_foot` - links of rechts
- `attacking_work_rate`, `defensive_work_rate` - werkethiek

Waarom SQLite?

De European Soccer Database is standaard beschikbaar in het SQLite-formaat. Dit betekent dat alle gegevens zijn opgeslagen in een enkel bestand (`database.sqlite`). SQLite is relationeel opgezet: de tabellen zijn met elkaar verbonden via primaire en vreemde sleutels, waardoor analyses op verschillende niveaus, zoals wedstrijden, teams en spelers, goed mogelijk zijn.

Daarnaast integreert SQLite uitstekend met R: via de packages DBI en RSQLite kan eenvoudig verbinding worden gemaakt en kunnen tabellen direct worden ingelezen als dataframes. Het gebruik van SQLite biedt hiermee een praktische en toegankelijke basis voor verdere analyses en visualisaties.

Voorbeeldcode: database openen en tabellen bekijken

Onderstaande R-code laat zien hoe de database kan worden geopend en hoe enkele tabellen kunnen worden bekeken:

```
library(DBI)
library(RSQLite)

# Verbinding maken met de database
connection <- dbConnect(SQLite(), "database/database.sqlite")

# Overzicht van alle tabellen in de database
dbListTables(connection)

# Eerste rijen van de Match tabel bekijken
matches_raw <- dbReadTable(connection, "Match")
head(matches_raw[, c("match_api_id", "date", "season",
```

```
"home_team_goal", "away_team_goal"]])
```

Deze code laat zien hoe de verbinding wordt gelegd, hoe je een lijst van tabellen krijgt en hoe je de belangrijkste gegevens van een tabel kunt inspecteren. Voor het volledige proces van het inlezen van alle tabellen is een apart R-script gemaakt: data_import.R.

data_import.R

```
# data_import.R
# Verbinden met SQLite database en de tabellen inlezen
library(DBI)
library(RSQLite)

# Verbinding maken met de database
connection <- dbConnect(SQLite(), "database/database.sqlite")

dbListTables(connection)

# Tabellen inlezen
countries_raw <- dbReadTable(connection, "Country")
leagues_raw <- dbReadTable(connection, "League")
matches_raw <- dbReadTable(connection, "Match")
players_raw <- dbReadTable(connection, "Player")
player_attr_raw <- dbReadTable(connection, "Player_Attributes")
teams_raw <- dbReadTable(connection, "Team")
team_attr_raw <- dbReadTable(connection, "Team_Attributes")

# Data opslaan als RData
save(countries_raw, leagues_raw, matches_raw, players_raw,
player_attr_raw, teams_raw, team_attr_raw, file =
"database/raw_data.RData")
```

Het script data_import.R is verantwoordelijk voor het verbinden met de SQLite database en het inlezen van de tabellen in R. Hiervoor worden de pakketten DBI en RSQLite gebruikt.

Eerst wordt met dbConnect(SQLite(), "database/database.sqlite") een verbinding gelegd met de database. Met dbListTables() kan worden gecontroleerd welke tabellen aanwezig zijn. Vervolgens worden de tabellen Country, League, Match, Player, Player_Attributes, Team en Team_Attributes ingelezen met dbReadTable().

Om het werken met de data in latere scripts efficiënter te maken, worden alle ingelezen tabellen samengevoegd en opgeslagen in een enkel bestand (raw_data.RData). Dit maakt het mogelijk om de ruwe data direct te laden in volgende stappen (preprocessing, EDA en visualisatie), zonder opnieuw de database te hoeven openen.

Data-acquisitie & Preprocessing

Data-acquisitie

De eerste stap in dit project bestond uit het verzamelen en inladen van de dataset. Hiervoor is de European Soccer Database gebruikt, een rijke dataset in SQLite-formaat met tabellen zoals *Country*, *League*, *Match*, *Player*, *Player_Attributes*, *Team* en *Team_Attributes*.

Voor het inladen van de tabellen is het script `data_import.R` ontwikkeld. Dit script maakt via de R-packages DBI en RSQLite verbinding met het bestand `Data/database.sqlite` en leest alle tabellen in als R-dataframes. Omdat dit proces relatief zwaar kan zijn en niet bij iedere analyse opnieuw uitgevoerd hoeft te worden, zijn de ingelezen tabellen gebundeld en opgeslagen in een enkel bestand: `raw_data.RData`.

Dit bestand vormt het uitgangspunt voor de preprocessing stap. Op die manier kan in volgende scripts snel en efficiënt met de data worden gewerkt, zonder telkens een nieuwe verbinding met de SQLite database te moeten maken.

Hoewel de dataset zeer rijk is, is ze niet direct bruikbaar voor analyse. Enkele belangrijke uitdagingen zijn:

- **Grote omvang:** de database bevat informatie van meer dan 25.000 wedstrijden, duizenden spelers en meerdere seizoenen, waardoor de data omvangrijk en complex is.
- **Missende waarden:** in tabellen zoals *Player_Attributes* ontbreken geregeld waardes voor spelersratings of werkethiek.
- **Inconsistente datatypes:** sommige velden zijn als tekst opgeslagen (bijvoorbeeld datums) terwijl ze in feite numeriek of Date moeten zijn.
- **Overbodige kolommen:** veel tabellen bevatten velden die niet relevant zijn voor dit project, zoals gedetailleerde technische velden of duplicaten van identifiers.

Preprocessing

Het preprocessingsproces is ingericht met de volgende doelen:

1. **Opschonen** - verwijderen of corrigeren van missende en inconsistente waarden.
2. **Structureren** - reduceren tot relevante variabelen, en correct instellen van datatypes.
3. **Verrijken** - creëren van nieuwe variabelen en samenvattende statistieken die de analyses krachtiger maken.
4. **Opslaan van schone data** - het genereren van een nieuw bestand (`clean_data.RData`) dat direct kan worden gebruikt voor Exploratory Data Analysis en Visualisaties

Stappenplan:

1. Selectie van kernvariabelen

Uit de ruwe tabellen zijn relevante kolommen geselecteerd voor de analyse:

- **Match:** `match_api_id`, `country_id`, `league_id`, `season`, `stage`, `date`, `home_team_api_id`, `away_team_api_id`, `home_team_goal`, `away_team_goal`.
- **Player_Attributes:** `player_api_id`, `player_fifa_api_id`, `date`, `overall_rating`, `potential`, `dribbling`, `finishing`.

- **Team_Attributes:** team_api_id, date, buildUpPlaySpeed, buildUpPlayPassing, chanceCreationPassing, chanceCreationShooting, defencePressure, defenceAggression.

2. Veilige conversie naar numerieke waarden

Veel kolommen zijn in de ruwe data als tekst of factor opgeslagen. Met een veilige conversiefunctie (safe_numeric) zijn deze kolommen geconverteerd naar numeriek, waarbij eventuele niet-numerieke waarden genegeerd worden. Geconverteerde kolommen zijn onder andere:

- **matches:** home_team_goal, away_team_goal
- **player_attr:** overall_rating, potential, dribbling, finishing
- **team_attr:** buildUpPlaySpeed, chanceCreationShooting, defencePressure

3. Opschonen van missende waarden

Numerieke kolommen met ontbrekende waarden zijn opgeschoond door de mediaan van de kolom in te vullen.

4. Conversie van datatypes

- **Datums:** kolommen zoals date in matches, player_attr en team_attr zijn omgezet naar het Date formaat.

5. Feature Engineering

Om analyses te verrijken, zijn nieuwe variabelen toegevoegd:

- **goal_difference:** verschil tussen doelpunten van thuis- en uitteam
- **match_result:** classificatie van wedstrijd als "Home Win", "Away Win" of "Draw".
- **total_goals:** totaal aantal doelpunten per wedstrijd

6. Competitienamen koppelen

In deze stap zijn de competitienamen gekoppeld aan de wedstrijden om de analyses beter te maken

7. Samenvattende statistieken

- **player_summary:** gemiddelde statistieken per speler voor overall_rating, potential, dribbling en finishing
- **team_summary:** gemiddelde tactische en verdedigende eigenschappen per team, zoals buildUpPlaySpeed, chanceCreationShooting en defencePressure.

8. Teamattributen koppelen aan wedstrijden

In deze stap zijn de teamstatistieken uit de tabel team_summary gekoppeld aan de matches dataset

preprocessing.R

```
# preprocessing.R

# Laden van benodigde packages
```

```

library(dplyr)
library(lubridate)

# Laden van ruwe data
load("Data/raw_data.RData")

# 1. Selectie van kernvariabelen
matches <- matches_raw %>%
  select(match_api_id, country_id, league_id, season, stage, date,
         home_team_api_id, away_team_api_id,
         home_team_goal, away_team_goal)

player_attr <- player_attr_raw %>%
  select(player_api_id, player_fifa_api_id, date,
         overall_rating, potential, dribbling, finishing)

team_attr <- team_attr_raw %>%
  select(team_api_id, date,
         buildUpPlaySpeed, buildUpPlayPassing,
         chanceCreationPassing, chanceCreationShooting,
         defencePressure, defenceAggression)

# 2. Veilige conversie naar numeric
safe_numeric <- function(x) {
  x_char <- as.character(x)
  suppressWarnings(as.numeric(x_char))
}

num_cols_matches <- c("home_team_goal", "away_team_goal")
matches[num_cols_matches] <- lapply(matches[num_cols_matches],
safe_numeric)

num_cols_player <- c("overall_rating", "potential", "finishing",
"dribbling")
player_attr[num_cols_player] <- lapply(player_attr[num_cols_player],
safe_numeric)

num_cols_team <- c("buildUpPlaySpeed", "buildUpPlayPassing",
"chanceCreationPassing",
"chanceCreationShooting", "defencePressure",
"defenceAggression")
team_attr[num_cols_team] <- lapply(team_attr[num_cols_team],
safe_numeric)

# 3. Opschonen van missende waarden
impute_median <- function(x) {

```

```

    if (is.numeric(x)) x[is.na(x)] <- median(x, na.rm = TRUE)
    return(x)
}

matches <- as.data.frame(lapply(matches, impute_median))
player_attr <- as.data.frame(lapply(player_attr, impute_median))
team_attr <- as.data.frame(lapply(team_attr, impute_median))

# 4. Conversie van datatypes
matches$date <- as.Date(matches$date)
player_attr$date <- as.Date(player_attr$date)
team_attr$date <- as.Date(team_attr$date)

# 5. Feature Engineering
matches <- matches %>%
  mutate(
    goal_difference = home_team_goal - away_team_goal,
    match_result = case_when(
      goal_difference > 0 ~ "Home Win",
      goal_difference < 0 ~ "Away Win",
      TRUE ~ "Draw"
    ),
    total_goals = home_team_goal + away_team_goal,
  )

# 6. Competitienamen koppelen
matches <- matches %>%
  left_join(leagues_raw %>% select(id, name), by = c("league_id" =
    "id")) %>%
  rename(league_name = name)

# 7. Samenvattende statistieken
player_summary <- player_attr %>%
  group_by(player_api_id) %>%
  summarise(
    avg_rating = mean(overall_rating, na.rm = TRUE),
    avg_potential = mean(potential, na.rm = TRUE),
    avg_finishing = mean(finishing, na.rm = TRUE),
    avg_dribbling = mean(dribbling, na.rm = TRUE)
  )

team_summary <- team_attr %>%
  group_by(team_api_id) %>%
  summarise(
    avg_buildUpSpeed = mean(buildUpPlaySpeed, na.rm = TRUE),
    avg_buildUpPassing = mean(buildUpPlayPassing, na.rm = TRUE),
  )

```

```

    avg_chanceCreationPassing = mean(chanceCreationPassing, na.rm =
TRUE),
    avg_chanceCreationShooting = mean(chanceCreationShooting, na.rm =
TRUE),
    avg_defencePressure = mean(defencePressure, na.rm = TRUE),
    avg_defenceAggression = mean(defenceAggression, na.rm = TRUE)
)

# 8. Teamattributen koppelen aan wedstrijden.
matches <- matches %>% left_join(team_summary, by = c("home_team_api_id"
= "team_api_id"))

# 9. Opslaan van schone datasets
save(matches, player_attr, team_attr, player_summary, team_summary,
countries_raw, leagues_raw, teams_raw, players_raw,
file = "Data/clean_data.RData")

```

Na deze stappen zijn de datasets volledig opgeschoond, verrijkt en geschikt voor analyse:

- **matches:** bevat per wedstrijd de uitslag, doelpunten, match_result, goal_difference, total_goals, gekoppelde competitienamen en teamstatistieken van het thuisspelende team.
- **player_attr:** bevat opgeschoonde spelersstatistieken zonder missende waarden.
- **team_attr:** bevat opgeschoonde tactische teamstatistieken, zoals build-up play, passing en verdediging.
- **player_summary & team_summary:** bevatten gemiddelde speler- en teamstatistieken, bruikbaar voor vergelijkingen en trendanalyses.

Deze schone en verrijkte datasets vormen een solide en consistente basis voor de Exploratory Data Analysis (EDA) en de daaropvolgende visualisaties en modellen.

Exploratory Data Analysis (EDA)

De Exploratory Data Analysis (EDA) vormt een cruciale fase binnen dit project waarin de opgeschoonde dataset systematisch wordt onderzocht om inzicht te krijgen in patronen, trends en onderlinge relaties tussen variabelen. Het doel van deze analyse is om de dataset niet enkel kwantitatief te beschrijven, maar vooral om onderliggende structuren en patronen zichtbaar te maken die later met behulp van visualisaties verder kunnen worden geïnterpreteerd.

De analyses in dit hoofdstuk zijn voornamelijk uitgevoerd op de tabel matches, afkomstig uit de opgeschoonde dataset `clean_data.RData`. Deze tabel bevat informatie over wedstrijden, doelpunten, teams, seizoenen en resultaten.

Het EDA-proces is uitgevoerd met R en richt zich voornamelijk op:

1. Het beschrijven van de dataset en controleren van volledigheid.
2. Het berekenen van kernstatistieken zoals doelpuntgemiddelden en uitslagverdeling.
3. Het analyseren van trends per seizoen en competitie.
4. Het onderzoeken van relaties tussen speelstijl en prestaties.
5. Het identificeren van verbanden tussen variabelen via correlatieanalyses

Algemene datasetverkenning.

De eerste stap van de EDA richt zich op het verkrijgen van een globaal overzicht van de dataset. Het doel is om de omvang, spreiding en structuur van de gegevens in kaart te brengen en inzicht te krijgen in de representativiteit van de data.

Code:

```
# 1. Algemene samenvatting van de dataset
cat("ALGEMENE SAMENVATTING\n")
cat("Aantal wedstrijden:", nrow(matches), "\n")
cat("Aantal unieke seizoenen:", length(unique(matches$season)), "\n")
cat("Aantal competities:", length(unique(matches$league_name)), "\n")
cat("Aantal teams:", length(unique(c(matches$home_team_api_id, matches$away_team_api_id))), "\n\n")
```

Output:

```
ALGEMENE SAMENVATTING
Aantal wedstrijden: 25979
Aantal unieke seizoenen: 8
Aantal competities: 11
Aantal teams: 299
```

Analyse:

De dataset omvat 25.979 wedstrijden verspreid over 8 seizoenen en 11 competities in Europa, met bijna 300 unieke teams. Deze omvang biedt voldoende diepgang voor statistische betrouwbaarheid en maakt vergelijkingen mogelijk tussen competities, teams en seizoenen. De aanwezigheid van meerdere seizoenen vergroot bovendien de mogelijkheid om trends in tijd te analyseren.

Basisstatistieken over doelpunten.

Een belangrijk aspect in voetbalanalyses is het scoringsgedrag van teams. Door middel van een samenvattende statistische analyse worden het gemiddelde, de mediaan en de verschillen tussen thuis- en uitdoelpunten berekend

Code:

```
# 2. Basisstatistieken over doelpunten
match_stats <- matches %>%
  summarise(
    gemiddeld_totaal_doelpunten = mean(total_goals, na.rm = TRUE),
    mediaan_totaal_doelpunten = median(total_goals, na.rm = TRUE),
    gemiddeld_thuisdoelpunten = mean(home_team_goal, na.rm = TRUE),
    gemiddeld_uitdoelpunten = mean(away_team_goal, na.rm = TRUE),
    gemiddeld_doelpuntverschil = mean(goal_difference, na.rm = TRUE)
  )

cat("BASISSTATISTIEKEN VAN WEDSTRIJDEN\n")
cat(sprintf("Gemiddeld totaal doelpunten: %.2f\n", match_stats$gemiddeld_totaal_doelpunten))
cat(sprintf("Mediaan totaal doelpunten: %.2f\n", match_stats$mediaan_totaal_doelpunten))
cat(sprintf("Gemiddeld thuisdoelpunten: %.2f\n", match_stats$gemiddeld_thuisdoelpunten))
cat(sprintf("Gemiddeld uitdoelpunten: %.2f\n", match_stats$gemiddeld_uitdoelpunten))
cat(sprintf("Gemiddeld doelpuntenverschil: %.2f\n", match_stats$gemiddeld_doelpuntverschil))
```

Output:

```
BASISSTATISTIEKEN VAN WEDSTRIJDEN
Gemiddeld totaal doelpunten: 2.71
Mediaan totaal doelpunten: 3.00
Gemiddeld thuisdoelpunten: 1.54
Gemiddeld uitdoelpunten: 1.16
Gemiddeld doelpuntenverschil: 0.38
```

Analyse:

Gemiddeld vallen er 2.71 doelpunten per wedstrijd, wat een vrij aanvallend karakter van Europese competities weerspiegelt. De mediaan van 2 doelpunten suggereert dat de verdeling iets naar boven is verschoven, veel wedstrijden eindigen met 2 a 3 doelpunten. De verschillen tussen thuis- (1.54) en uitdoelpunten (1.16) bevestigen het statistisch bekende thuisvoordeel, waarbij thuisploegen gemiddeld 0.38 doelpunten meer scoren. Deze statistiek vormt de basis voor latere analyses rond winstkansen en teamvoordelen.

Verdeling van wedstrijdresultaten.

De volgende stap onderzoekt hoe vaak wedstrijden eindigen in winst, verlies of gelijkspel. Door deze verdeling te analyseren wordt duidelijk hoe competitief en evenwichtig de dataset is.

Code:

```
# 3. Verdeling van wedstrijdresultaten
result_distribution <- matches %>%
  group_by(match_result) %>%
  summarise(aantal = n()) %>%
  mutate(percentage = round(aantal / sum(aantal) * 100, 2))

cat("\nVERDELING VAN WEDSTRIJDRESULTATEN\n")
print(result_distribution)
```

Output:

```
VERDELING VAN WEDSTRIJDRESULTATEN
# A tibble: 3 × 3
  match_result aantal percentage
  <chr>         <int>      <dbl>
1 Away Win      7466      28.7
2 Draw          6596      25.4
3 Home Win     11917      45.9
```

Analyse:

Bijna 46% van de wedstrijden eindigt in winst voor het thuisteam, terwijl slechts 29% wordt gewonnen door het uitteam. Gelijkspelen (25%) komt minder vaak voor, maar vormt een substantiële categorie. Deze verdeling benadrukt dat het thuisvoordeel niet enkel in doelpunten, maar ook in eindresultaten tot uiting komt.

Gemiddelde doelpunten per seizoen en competitie.

Om de evolutie van scoringspatronen te bestuderen, is berekend hoe het gemiddelde aantal doelpunten per seizoen en competitie varieert.

Code:

```
# 4. Gemiddelde doelpunten per seizoen en competitie
trend_season_league <- matches %>%
  group_by(season, league_name) %>%
  summarise(
    gemiddeld_totaal_doelpunten = mean(total_goals, na.rm = TRUE),
    gemiddeld_thuisdoelpunten = mean(home_team_goal, na.rm = TRUE),
    gemiddeld_uitdoelpunten = mean(away_team_goal, na.rm = TRUE),
    aantal_wedstrijden = n(),
    .groups = "drop"
  ) %>%
  arrange(season)

cat("\nGEMIDDELDE DOELPUNTEN PER SEIZOEN EN COMPETITIE\n")
print(trend_season_league)
```

Output:

```
GEMIDDELDE DOELPUNTEN PER SEIZOEN EN COMPETITIE
# A tibble: 88 × 6
  season league_name      gemiddeld_totaal_doelpunten gemiddeld_thuisdoelpunten gemiddeld_uitdoelpunten aantal_wedstrijden
  <chr>   <chr>                <dbl>                <dbl>                <dbl>                <int>
1 2008/2009 Belgium Jupiler League      2.79                1.63                1.16                306
2 2008/2009 England Premier League      2.48                1.4                1.08                380
3 2008/2009 France Ligue 1              2.26                1.29                0.971               380
4 2008/2009 Germany 1. Bundesliga        2.92                1.70                1.22                306
5 2008/2009 Italy Serie A                2.6                1.52                1.08                380
6 2008/2009 Netherlands Eredivisie      2.84                1.71                1.13                306
7 2008/2009 Poland Ekstraklasa          2.18                1.34                0.846               240
8 2008/2009 Portugal Liga ZON Sagres     2.3                1.23                1.07                240
9 2008/2009 Scotland Premier League     2.40                1.32                1.08                228
10 2008/2009 Spain LIGA BBVA             2.90                1.66                1.24                380
# 1 78 more rows
# Use `print(n = ...)` to see more rows
```

Analyse:

De resultaten tonen aan dat het gemiddelde aantal doelpunten per seizoen relatief stabiel blijft binnen individuele competities, met slechts kleine schommelingen van jaar tot jaar. Dit wijst op consistente scoringspatronen binnen Europese competities over de periode 2008 - 2016. Toch zijn er duidelijke structurele verschillen tussen competities.

Competities met hoge doelpuntgemiddelden:

- Nederlandse Eredivisie (vaak rond de 3.0 goals per wedstrijd).
- Zwitserse Super League (regelmatig boven de 3.0).
- Duitse Bundesliga (doorgaans rond de 2.8-3.0).

Deze competities staan bekend om aanvallende speelstijlen, minder compact verdedigen en tactieken die leiden tot open wedstrijden.

Competities met lagere gemiddelden:

- Franse Ligue 1 (ca. 2.3-2.5 goals).
- Poolse Ekstraklasa (vaak onder de 2.4).
- Italiaanse Serie A (meestal 2.5-2.7)

Hier zie je vaker een meer defensieve structuur, nadruk op organisatie, compacter spel en minder open wedstrijden.

Correlatie tussen teamstijl en prestaties

Om te onderzoeken hoe verschillende speelstijlkenmerken van teams met elkaar samenhangen, is een correlatiematrix berekend voor de belangrijkste teamattributen: opbouwsnelheid, passnauwkeurigheid bij opbouw, passing in kanscreatie, schieten bij kanscreatie, druk zetten en agressiviteit in verdediging

Code:

```
# 5. Correlatie tussen teamstijl en prestaties
team_play_corr <- matches %>%
  select(
    avg_buildUpSpeed, avg_buildUpPassing, avg_chanceCreationPassing,
    avg_chanceCreationShooting, avg_defencePressure, avg_defenceAggression
  ) %>%
  drop_na() %>%
  cor(use = "complete.obs")

cat("\nCORRELATIE TUSSEN TEAMATTRIBUTES\n")
print(round(team_play_corr, 2))
```

Output:

	avg_buildUpSpeed	avg_buildUpPassing	avg_chanceCreationPassing	avg_chanceCreationShooting	avg_defencePressure	avg_defenceAggression
avg_buildUpSpeed	1.00	0.44	0.35	0.04	-0.07	0.18
avg_buildUpPassing	0.44	1.00	0.15	-0.16	-0.21	0.11
avg_chanceCreationPassing	0.35	0.15	1.00	0.21	0.16	0.11
avg_chanceCreationShooting	0.04	-0.16	0.21	1.00	0.25	0.16
avg_defencePressure	-0.07	-0.21	0.16	0.25	1.00	0.37
avg_defenceAggression	0.18	0.11	0.11	0.16	0.37	1.00

Analyse:

- Sterke positieve correlaties zijn zichtbaar tussen avg_buildUpSpeed en avg_buildUpPassing (0.44) en tussen avg_buildUpSpeed en avg_chanceCreationPassing (0.35). Dit geeft aan dat teams die sneller opbouwen vaak ook nauwkeuriger passen en meer kansen creëren via passing.
- avg_defencePressure en avg_defenceAggression vertonen een matige positieve correlatie (0.37), wat suggereert dat teams die agressiever verdedigen ook meer druk uitoefenen op tegenstanders.
- Over het algemeen zijn de correlaties tussen aanval- en verdedigingsvariabelen vrij laag of negatief, wat erop wijst dat een aanvallende speelstijl niet per se samengaat met een sterk verdedigend profiel.

Thuis- versus uitprestaties

Om de invloed van locatie verder te kwantificeren, zijn thuis- en uitprestaties direct met elkaar vergeleken.

Code:

```
# 6. Thuis- versus uitprestaties
home_vs_away <- matches %>%
  summarise(
    gemiddeld_thuisdoelpunten = mean(home_team_goal, na.rm = TRUE),
    gemiddeld_uitdoelpunten = mean(away_team_goal, na.rm = TRUE),
    thuiswin_percentage = mean(match_result == "Home Win") * 100,
    uitwin_percentage = mean(match_result == "Away Win") * 100,
    gelijk_percentage = mean(match_result == "Draw") * 100
  )

cat("\nTHUIS- VERSUS UITPRESTATIES\n")
print(round(home_vs_away, 2))
```

Output:

	gemiddeld_thuisdoelpunten	gemiddeld_uitdoelpunten	thuiswin_percentage	uitwin_percentage	gelijk_percentage
1	1.54	1.16	45.87	28.74	25.39

Analyse:

De cijfers laten duidelijk zien dat teams gemiddeld beter presteren in thuiswedstrijden. Niet alleen scoren ze meer doelpunten (1.54 tegenover 1.16 uit), maar de thuiswinstkans ligt ook aanzienlijk hoger (45.9% tegenover 28.7%). Dit wijst op een duidelijk thuisvoordeel.

Factoren zoals steun van het publiek, vertrouwdheid met het speelveld, minder reistijd en mogelijk gunstige arbitragebeslissingen kunnen bijdragen aan dit voordeel.

Competitieanalyse

Om verschillen tussen leagues te onderzoeken, is een analyse per competitie uitgevoerd met nadruk op doelpunten en resultaatverdeling

Code:

```
# 7. Competitieanalyse
# Analyse per competitie: gemiddelde doelpunten, winstpercentages, enz
league_analysis <- matches %>%
  group_by(league_name) %>%
  summarise(
    gemiddeld_doelpunten = mean(total_goals, na.rm = TRUE),
    thuiswinst = mean(match_result == "Home Win") * 100,
    uitwinst = mean(match_result == "Away Win") * 100,
    gelijkspel = mean(match_result == "Draw") * 100,
    wedstrijden = n(),
    .groups = "drop"
  ) %>%
  arrange(desc(gemiddeld_doelpunten))

cat("\nCOMPETITIEANALYSE (TOP 10 OP GEMIDDELDE DOELPUNTEN)\n")
print(head(league_analysis, 10))
```

Output:

```
COMPETITIEANALYSE (TOP 10 OP GEMIDDELDE DOELPUNTEN)
# A tibble: 10 × 6
  league_name      gemiddeld_doelpunten thuiswinst uitwinst gelijkspel wedstrijden
  <chr>              <dbl>         <dbl>    <dbl>    <dbl>         <int>
1 Netherlands Eredivisie      3.08      47.8     28.4     23.7          2448
2 Switzerland Super League    2.93      45.7     30.0     24.3          1422
3 Germany 1. Bundesliga      2.90      45.2     30.4     24.4          2448
4 Belgium Jupiler League      2.80      46.9     28.5     24.6          1728
5 Spain LIGA BBVA             2.77      48.8     28.0     23.2          3040
6 England Premier League      2.71      45.7     28.5     25.8          3040
7 Scotland Premier League     2.63      41.7     33.8     24.5          1824
8 Italy Serie A                2.62      46.6     27.0     26.4          3017
9 Portugal Liga ZON Sagres     2.53      44.2     29.8     26.0          2052
10 France Ligue 1              2.44      44.7     27.0     28.3          3040
```

Analyse:

De resultaten tonen duidelijke verschillen in scoringsintensiteit tussen competities.

- De Eredivisie is de meest doelpuntrijke competitie in deze dataset, met gemiddeld 3.08 doelpunten per wedstrijd.
- Ook competities zoals de Zwitserse Super League (2.93) en de Bundesliga (2.90) scoren hoog.
- Aan de andere kant behoren competities zoals de Ligue 1 (2.44) en de Primeira Liga (2.53) tot de laagste gemiddelde doelpuntentotalen

Correlatiematrix tussen doelpuntgerelateerde variabelen

Tot slot is de correlatie berekend tussen verschillende doelpuntgerelateerde variabelen om inzicht te krijgen in hun onderlinge samenhang.

Code:

```
# 8. Correlatiematrix tussen doelpuntgerelateerde variabelen
corr_data <- matches %>%
  select(home_team_goal, away_team_goal, total_goals, goal_difference) %>%
  drop_na()

cor_matrix <- cor(corr_data)
cat("\nCORRELATIEMATRIX TUSSEN DOELPUNTERELATEERDE VARIABELEN\n")
print(round(cor_matrix, 2))
```

Output:

```
CORRELATIEMATRIX TUSSEN DOELPUNTERELATEERDE VARIABELEN
      home_team_goal away_team_goal total_goals goal_difference
home_team_goal      1.00      -0.06      0.73      0.77
away_team_goal     -0.06      1.00      0.63     -0.69
total_goals         0.73      0.63      1.00      0.13
goal_difference      0.77     -0.69      0.13      1.00
```

Analyse:

De correlatiematrix toont duidelijke relaties tussen de doelpuntgerelateerde variabelen:

- Home_team_goal en total_goals hebben sterke positieve correlatie ($r = 0.73$). Dit is logisch: hoe meer het thuisteam scoort, hoe hoger het totaal aantal doelpunten per wedstrijd.
- Away_team_goal en total_goals zijn ook positief gecorreleerd ($r = 0.63$). Beide bijdragen immers aan het totaal aantal goals.
- Goal_difference correleert sterk positief met home_team_goal ($r = 0.77$). Hoe meer goals het thuisteam maakt, hoe groter de kans dat het doelpuntverschil in hun voordeel uitvalt.
- Er is een sterke negatieve correlatie tussen away_team_goal en goal_difference ($r = -0.69$). Dit is logisch: als het uitteam vaker scoort, wordt het thuisdoelpuntverschil kleiner.
- De correlatie tussen total_goals en goal_difference is relatief zwak ($r = 0.13$), en dus is het totale aantal doelpunten slechts beperkt gerelateerd aan welk team de wedstrijd domineert.

Samenvattend

De Exploratory Data Analysis biedt een helder inzicht in de structurele eigenschappen van de dataset. De belangrijkste bevindingen zijn:

- **Consistente trends:** Het gemiddeld aantal doelpunten blijft door de seizoenen heen relatief stabiel.
- **Thuisvoordeel:** Thuisteams scoren vaker en winnen aanzienlijk meer wedstrijden dan uitteams.
- **Invloed van speelstijl:** Meer aanvallende teamattributes tonen een duidelijke samenhang met een hoger aantal doelpunten.
- **Competitieveverschillen:** Het aantal doelpunten verschilt per competitie, wat aansluit bij bekende nationale speelstijlen.
- **Sterke relaties tussen variabelen:** Positieve correlaties tussen thuisdoelpunten en totaal aantal doelpunten bevestigen de onderlinge afhankelijkheid.

Deze resultaten vormen de analytische basis voor de volgende stap: Data Visualisatie, waarin de patronen visueel worden weergegeven voor verdere interpretatie en presentatie.

